

基于个人观察的GPT降智事件的统计报告与深入分析——我带来了全面的视角，珍贵的数据，大胆的推测，以及同在的心理支持【完稿于26-09-27日晚】

@ https://github.com/Foxmir/GPT_Intelligence_Reduction_Incident_Investigation_Report

@ 2026-09-25日（UTC+8）晚8：00 我从现在开始写。全文纯人脑子，纯手打。

1. 我以@Foxmir个人的名义对截至到2026-09-27日晚7点前的信息理解和推测负责
 1. 我必须说明！我最初根本没打算写这种东西，当初的所有沟通也只是出于纯粹的个体痛苦和好奇心。但是，随着越来越多的信息反馈和沟通展开，使得我意识到，也许我应该写一个。
 2. 整篇文章因为要进行大量的分析，我几乎完全对曾经所有的沟通体验采取了疏离姿态。你也许会辨认出当我说：“某位网友”的时候，恰恰就是在说你。请不要感到被冒犯，我和当初与你沟通时，饱有一样的真诚。
 3. 我会诚实地抛出到截稿日为止，所有我知道的/汇总的/推理的内容，边界，置信度。
 4. 同时这里面可能包含了大量的基于茧房的个人偏见，视野盲区，。为了简化管理，我会给结论打上红绿黄的标签，代表我对这句话（无论说的好事/坏事/描述/推论）有多么确定。
 1.  我非常肯定 ← 你基本可以信赖这条判断
 2.  我有些怀疑，但基本肯定 ← 请跟我一起想想
 3.  不太好说，我自己也不太确定 ← 随便听听就好
 2. 看完这篇文档后，不需要再找我问我已经讲明的内容，我也没有额外能够讲明的。
 3. 由于个人精力，我之后不会再逐个回复，不承诺后期跟进最新内容
 4. 仍然欢迎大家相互留言，彼此支持
 5. 该文档不附带交流群。文中提到的群我都是临时加入的**。大家在自己原有的群里/论坛上相互交流即可。
 6. 如果你有可靠的好消息，请留言；如果我有，我会发新帖子，但不承诺这点。
 7. 尽管该文档面向的讲解对象是遭遇此次gpt降智事件影响的普通用户，但出于分析的需要，文中有大量的数据，结构层级，边界防护等。希望我随心所欲的写作风格能给这种枯燥且略显罗嗦的分析架构带来阅读动力。
 8. 同时，我很清楚，这份资料对于密切关注此次事件的大量中间机构的价值。我没有更多可以提供的内容了，联系是不必要的。坦露一如下文。
 9. 欢迎大家转发，引用，分发！我会全平台公开此文档，以求帮助更多人理清情况。
 10. 再次！感谢之前参与讨论，支持和反馈的所有关注者！
-

核心结论先行(基本上看完这个就行，更好奇细节再去通读全文（正文共42000字左右）：总-分结构，序号对应。提示词见文末第15节可供复制)

1. ● **降智时间**：降智持续大概已经至少半个月，尽管有些用户不认为自己之前被降智。在刚刚的新模型发布日期后，降智行为依然存在，但降智规则同步更新了。

2. ● **检测降智的方法/标准**：

1. **检测推理能力，最可靠，降智结果不好判断**：

1. 不联网，用代码画鸛鹇（或其他动物）的svg图片目前仍然是最主流；但半好不好的时候很难说

1. 6系列有特殊风格，基本上出现该风格，就是6，但luan,sol,as的区分不明朗

2. **回答出问题的思考时间长短**：这是最直观的感受，降之后答案很差，而且，往往回答也快。但也存在少数情况正常模型正常回答时是快的，这个很难共享判断。一般只用于触发用户怀疑 → 进入正常诊断流程。以及用于在网上相互沟通信息。只要说一句，回答超快，大家就明白降智了。

2. **可高度怀疑的，6和5.6的语言风格差异，但仅仅出于感觉**：该方法无法推广，仅用于用户个人报告，主观程度很重。**真正的6**似乎能留给人以**非常简洁的高度理解力**（我用的少），这和5.6大不相同。6的话似乎更少，更精准。同时听说**似乎6更爱主动提问**，得到明确指令后更愿意一口气帮你干完。非常熟悉5.6的用户可能在被灰度到6的时候感到很不舒服。同时**6→5.6的情况相对少**，大概收到过3-4次反馈），**要降智基本是6/5.6→5.5**。

3. **检测有没有路由到其他模型，不太检测推理能力。该方法需要优秀的大批量题目来提高可靠性，降智结果很清晰：内部知识测试**。下文细谈，我反思了包括网友的提问方式/我之前给出的那批提示词，**仍然不够好！**哎😞但我并没有再准备一套更棒的提示词了（大家之后可以根据文中的建议自己再生成一套，或者干脆，就用这个旧的！）。我现在感到混乱。我需要诚实地纠正一些之前的和大家在沟通中交流的结论。

4. **答错肯定有问题！但答对，未必没问题！的一些测试**：

1. **能检测推理能力，但结论相对单一**：

1. **糖果题**：29不对，21对。但正常能力下，哪个模型哪个思考等级是该题的边界，目前没有统一定论，所有人似乎都用该题测5.6，也测6

2. **原理似乎可靠，但结论？也有些单一**

1. **model trace**，一个github开源工具，检查模型指纹。我个人认为地位上上面一样。

5. **有人报告有效，但我没碰过，不表态**：

1. 消息回答出现**首字延迟**超过xx秒，代表降智

2. 画鸛鹇的时候，**思考链条**出现什么“ ”（我纯忘了网友说的啥，好像是“冠内”？）两个**中文字**就代表降智

3. **网页版chat命名**时，如果英文命名挂上了“**中文的莫名其妙的后缀**”，说明没降智

4. 牛奶题

6. 明确失效/大概率失效：（到目前为止）

1. 🟡抓路由已经抓不出了6-luna,6-sol的区别了（下文在各个部分提及sub2api）
2. 🟢浏览器插件检查chat降智与否也失效
3. 🔴**Codex State Kit**:有些人是因为工具加群，但实际上，我看到几乎使用的每个人（大概4-5个左右）都主动报告看不懂好像出错了，请教如何判断之类的。由1-2个人明确回应说不好用，失效了。与此同时，依然有人相互宣传该工具。我本人没用，不明确。

7. 我个人虽然没碰过，但一看就觉得不靠谱：

1. ❌发送hi，然后对方回复“what can I do for you? ”，这句话对，其他不对

3. 普遍的降智程度(▲ ▲ 机制假设，和进一步的推论在内部展开，参见下文)：

- 目前，统计中没有关注不同订阅（如plus 5x, 20x），一视同仁
- 没有chat，work的主动测试，只有一些零星的网友的主动反馈

1. 🟢在网友帮助下，我们在codex内部，根据一批内部知识测试题目做了大量测试【因此测试结果高度依赖测试题的可靠性】【非鹌鹑，鹌鹑不好判定】，目前情况

1. 占比至少60%以上：大部分人6-sol,6-as可用（至少有max可用）但6-luna-max,5.6-sol-max不可用（更低的模型没关注）（max就是最大思考等级，ultra只是跟多子代理，不算更聪明）
2. 剩下的，部分连6-sol-max，也用不上，还有一部分，全军覆没，6-as-max也用不上，意思是全线降智。
3. 在同一个模型内部，根据思考等级，每个人可用程度不同。呈现出的效果是，比如无论6的哪个模型，luna,sol,as，或者是5.6-sol,它们当中更低的思考等级比如low，medium往往更容易只回答出5.5及以下的问题，而对自己应该答对的题目却回答不清楚。
4. 同时，降智是波动的！以上情况是我个人的平均感知。

2. chat信息更多一些，work我拒绝回答：

1. 🟡影响chat的机制理论上跟codex一样，是波动的，且会被标记的
2. 🟢也不存在一个大家共享的一起好起来，一起坏了的现象，看起来也像是背后有一套算法，然后，每个人独立表现，但当然，某些风险因素可以共享（比如gpt发布了新模型之类的）。似乎大家能相互找到一些效果相似的同伴，但，由于我有稍微多聊一些，我感觉，如果你想找的话，可能还会找到更多效果不一样的同伴。

3. 各产品降智一致性：

1. 🟢chat ,work（网页端和codex端没特别区分过），codex，手机app四者降智行为并不一致！
2. 🟡但chat和app，似乎比codex要更严重，没验证，纯个人看法，

4. 灰度：

1. ●流传的说法：如果你用5.6的模型，它突然变得也还算好用，但是风格完全不同了，尤其是测试题做出来6的题目了这就是临时被官方选中，想让你测试新模型的效果。是秘密进行的灰度测试。当然，我也认为这个说法可靠。
2. ●好像依然在灰度？理论上讲，新模型发布了以后没有必要再灰度了。但是，我有收到大概1-2份反馈，以及我自己也遇到5.6的模型，回答出6的题目。写到这里头好痛，不想想了。感觉题目不可靠导致的。或者我对于灰度理解不到位。
3. ●我往往跟网友说，你别管，一会就没了。天知道一会没了是正常灰度测试自然消失，还是用着用着自然降智。不知道，反正一会就没了。
4. ●我自己乐意发现灰度到6，觉得自己赚了，恨不得让它赶紧干活，但是大概1成的网友很不喜欢5.6灰度到6，希望灰度快点走开。

5. ●网友目前普遍的态度和状况：

1. 大约有2-3成的网友对自己模型当前的表现感到满意，
2. 超过一半以上的网友在沟通互动中，以及在宣传自己降智不降智的过程中，都是以6-as-的较高思考等级 + 画鹤鹑，进行展示和定性的。
3. 少于1成（甚至更少但很突出）的网友进行了不同程度的付费优化，包括购买新的不降智的号，付费尝试找路子解除。
4. 付费找解决办法的用户中，更少的部分的网友切实面临了被骗的风险。（我就聊了1个，最后还好退钱了，一买一退，损失300。）病急乱投医的急切感受此刻产生的行为驱动力很强。
5. 想要出手的人，看起来略微比想要收号的人多一点，基本持平，至少往往没那么巧碰面，由于我长期群里消息所以讲。但一个号商一般不仅仅只吃一个号，则基本处于要想出手，总能出得了的局面。价钱压得比平时低很多，毕竟降智号。但依然根据账号质量价格不同，差异较大。

4. 标记：

1. ●标记时间：根据网络信息，这里存在一个 250秒，也就是大概4分钟的检测周期，每周期打新标记，并根据标记结果决定之后的降智程度。
2. ●标记属性：
 1. 这里似乎存在一个多维度（多因素）共同组成的标记规则
 2. 但该标记似乎也并非单纯的降智/不降智的二元标记，似乎是带有不同降智程度的标记。
 3. 似乎不存在一个扭转全局的唯一因素。
3. ●产生标记的变量有哪些：简体中文是比较明确的一项风险因素，其他因素没有实验，只是推测和个人理解，信息对方当然全采集，但什么变量明显有影响，下文细说。（capacity报错的事情也在这里顺带提及）

1. ●连续性的使用语言倾向(只测试了中英文，从理论上讲，繁体中文应该也ok，没测试)
2. ●ip：不用说
3. ●并行对话/多个子智能体同时运行：高度怀疑会导致降智
4. ●累积用量：我比较认可，但没测试过
5. ●订阅等级：20x，似乎，比plus 风险更高，有少量明确信息支持，但没测试过。也不排除是其他混淆因素引起，比如用量
6. ●新旧账号：有一些不太可靠的证据，但我比较支持新旧账号都可能被降智。（降智程度是另一回事）
7. ●国内国外：
 1. 国内，几乎大部分人感觉都受影响了。当然明确有国外的华人，以及纯外国人受影响，但似乎在外国的圈子里比例则非常低！
 2. 同时似乎通过外国人的**人脸验证**是一个好因素。
8. ●各种反代信号：是明确危险的，但这里不确定是因为反代软件本身可能也足够聪明。两者始终处于动态博弈中。

4. 同一对话的标记连续性：

1. ●同一个对话如果被发现降智，后续聊天依然会被标记（下文细说，我也不太确定，有相互冲突的证据）

5. 应对方法：

1. ●（中高置信度吧）目前为止，比较可靠的是，连续性的英文使用倾向能够改善降智，增多不降智的模型（大概繁体中文也可以，没测试）
2. ●但目前似乎还没有可靠的一劳永逸的，简便方法
3. ●关于“抹除标记+打上干净标记”（似乎对应圈子里的“打票”一词？）：我纯门外汉，尝试硬翻译下。由于每4分钟用户行为就可能生成一个脏的标记，则你必须每4分钟内，就替换上一个干净标记，如此密集的探测频率导致不停生成干净标记的成本会逐渐攀升，不可为继。
4. ●清除浏览器cookie后对chat的降智可能有效。来自1-2位网友的自主分享，尤其一位网友提到网页端UI变化后出现了降智并通过清除cookie好转。（但它的好转不排除其他原因）。同时有看到另一位网友在宣传自己的降智办法大组合（常见的那些，里面也包含了清除浏览器cookie）
5. ●24日晚出现了一个通过excel内窗口（通过excel软件/网页版excel）登录gpt账号，并反代出来到codex里使用模型的方式。目前已经有大概至少2-3个以上的开源项目支持该操作。大家流传这是不降智的，至少能用的模型少一些。但截止到发稿日，已经有**非常明确的封号信息**。但依然还有很多人正在使用。（账号的珍贵性对于不同用户而言是不同的，这影响了它们对风险的接受程度。但如果你是普通用户，你需要知道这一点）
 1. 我个人没有尝试，它毕竟是反代，个人是保守风格，不爱折腾。

2. 一句忠告放在这里：新鲜工具可能在解决问题的同时，引入新的问题或风险。

6. ●用苹果ios系统付费？还是啥来着可以获得不降智的效果。够呛！我几乎完全没信息。听了那么一嘴。

7. ●静置，美国ip，2FA验证，IP和时区一致，退出重新登陆之类的。都属于影响“标记”的因素之一。且都属于理论上有帮助，但帮助大小不明确。但该标记是滚动更新，所以，这些措施往往做了之后即刻有效，却几分钟内很快失效，再次降智。但26日也有网友自发反映这些组合大礼包后有效，恢复了正常（没拉着它做测试，仅供参考吧，可信度不高）。（原因解释具体参见4.4.3）

8. ●sub2api或同类的方法：当然有风险，但下文详细说明。

6. 降低额度：●这个非常明确，也有强证据，几乎人皆知。但降多少没关注过。

7. 申诉邮件：

1. ●十封有9.5封都是敷衍和踢皮球。哪怕是问题伪装成技术bug请求技术专员跟进。有1-2个网友说自己有效。够呛，不可验证

2. ●但好像如果退订，退钱不及时的话还是可以通过申诉邮件退的。

8. 中转站此刻什么状态：

1. ●传言：有人在飞机上花6万块买了秘诀！（翻白眼）中转站正在积极筹备。

2. 买卖信号：

1. ●我仅看了两个群里，很多人因为自己的账号降智都想出手这不难理解。每个群大概200人，里面大概有4-5个人，在2天之内积极想要买入。理由不明。

1. ●在赌一把，后期好转赚大钱

2. ●赶紧出手，卖给病急乱投医的人

3. ●打信息差骗点钱

4. ●真的想办法

2. ●我没用过中转站，据说中转站的倍率还是很高（我硬理解：大概是不降智的，好的号和号的api还是少，所以卖的贵）

3. 研究信号：

1. ●它们在积极研究。毕竟它们能搭中转站肯定自己也懂技术，最重要，它们赚钱的驱动力更强。网上流传的技术方法（就是上文提到的那个干净标记的方法）好像就是来自它们。

2. ●不过目前看起来进展就那样

9. Openai官方什么状态：

1. ●推测：gpt官网似乎刻意制造了带有针对倾向的降智行为，并非技术bug或者临时波动。目的可能是多样的。

2. ●各种申诉邮件似乎都是敷衍和打哈哈，大量的同类信息反馈依然长时间维持这种姿态本

身就是回答。

3. ● 据说在github上codex的评论区很多同类留言，但官方似乎没有处理的意思
4. ● Tibo是个营销怪，他非常活跃！也很喜欢积极互动，尤其是那些说他们家产品好的。他的积极露头给了很多网友在他帖子下产生大量负面互动的机会。但是他！似乎很少正面回应，看起来就好像是“刻意忽略”。
5. ● 官方（媒体）26日宣布即将推出50x的订阅，似乎野心勃勃要供应更多。
 1. ● 因为刚刚6-as上台遇到的取消20x的订阅，包括大家的使用效果，这说明对应了明确的算力不足，（没关注是不是有什么算力大大缓解了的新闻）但现在这种战略下，通过严厉风控挽回导向中转站的钱，同时把算力省下供应将来的50x用户，还顺便防范了被蒸馏。对openai来说都非常合算。（后面这些纯个人理解）
6. ● 9月29日，openai高调宣传的“开发者大会”，并宣传带来新的工具/功能。
 1. ● 这个节点前后可以留意下降智行为的变化。毕竟刚刚发布6-luna,6-sol的时候，降智规则就同步更改了。（当然不是改好，似乎更迷惑了）

10. 综合的原因推论，纯个人推测：

1. ● 算力不足
2. ● 营销需求
3. ● 对于反代，号商的打击，这一点是明确的，只是好像最近特别上心，特别认真。可能出于打击行为，而舍弃了其他正常的普通中国用户。也不排除战略转变。
4. ●/● 防范蒸馏：必然的
5. ● 战略变化：不排除从“纯商人”身份，转向一个“只赚特定方向钱的商人”身份，像claude那样。但支持信号不太充分。

11. 全文总结：参见文末对应序号11

12. 个人预期：

1. 纯个人，我个人对一个月内能明显改善持有悲观态度。
2. 我个人需求比较少，所以比较灵活。我个人打算临时多花钱过渡，下月订阅费扣除前再评估（新方案暂无）。
3. 除了可靠的好消息我可能会主动发帖外（不承诺这点），其他信息不再跟进。默认不再参与回复和互动。也没有交流群。鼓励大家分享该文档，彼此之间多多交流。

13. 同在的心理支持（我的爱在这里）

14. 致谢

15. 附录：内部知识测试的完整提示词

结论边界&可靠性

1. ●我的基线：

1. 我plus规规矩矩的普通用户。普通网络，纯个人用，日常聊天，写小软件自己玩。
2. 但我以codex为主，chat用的少，work几乎不用。下面提到的各种测试，也是来自codex的测试。

2. ●信息来源：截止到此刻。25-晚 23：00

1. 🚧非常有限的渠道，所以，采样偏差也会很大！但这是我个人能力的极限。
2. 我大概发了4-5篇帖子，然后通过评论区大概有1000条互动，私信大概30人左右，基本上是信息透彻交换。
3. 两三个小群，大概累积不超过500人次，消息不落地跟进大概2-3天以上（我忘了什么时候进群的了，头很痛）。群里和网友一起一步步测试，大概有？少说30-50人吧。
4. 内网小红书刷了大量帖子，B站看了一两个视频，外网x看了很多互动，但没有看到可靠方法，主要是在抱怨的。
5. 其他没去。包括linux.do，但群里的人会转这里的帖子过来，所以看过一些流传比较广的。

3. ●信息质量：

1. 我认为我聊的小红书的网友因为是主动评论和主动私信我的，所以互动质量高一些，还有一些网友会主动反馈新变化。只不过纯小白要解答的也不少。
2. 群里的网友因为是我主动的，我需要先被信任，对方有成本，所以互动2成大概是无效/混杂的，3成部分有效，5成是还比较可靠的。
3. 外网，骂声一片。就是骂。还有被其他不降智的外国网友围观的羞耻感。没看到啥有用的。主要看到一些官方的不爱理睬的姿态。

4. 测试题本身的可靠性：

1. 😞😞😞😞😞😞😞😞这一行专门用来哭泣
2. 我起初信誓旦旦认为我给出的那组测试内部知识的测试题非常可靠，但是25日晚上写稿前临时的测试使得我改观了看法，一想到这里我就头皮发紧，**我们之前得出的很多结论（比如降智分界线，英文超级有效！）是在这个不太可靠的测试题上展开的。这非常影响结论的可靠性。**但别担心，我们依然拿到一些东西，**只是我要重新解释一些现象，并收紧一些边界。**
3. 我再也不能信誓旦旦了，我也很疲惫，所以没有同时提供一份更可靠的测试题，不过别担心，我会给出建议，你自己去生成即可。

0. 以下是按序号对应上文的“结论先行”，细节很多，废话可能也不少。看完结论先行基本上就可以了。如果需要直接拉到文末复制提示词自己玩玩即可。如果还敢兴趣，再按序号挑你感兴趣的看

1. 降智时间

- **降智时间**：降智持续大概已经至少半个月，尽管有些用户不认为自己之前被降智。在刚刚的新模型发布日期后，降智行为依然存在，但降智规则同步更新了。
- 个人是**重度codex用户**，我已经因为发现降智而**神经兮兮**长达半个月了。应该是从20x订阅被取消那之前一个周开始的吧。忘记了。不排除降智时间更早/更晚。
 - 我能看到很多小红书上很多用户处在完全不同的状态，这让我有些难过。
 - 很多人可能已经意识到软件降智了，尽管大家都没什么特别好的主意，但至少你能主动控制是否使用。
 - 而有些网友，发帖子表达愤怒，甚至是**自责**，在跟gpt的沟通中感到挫败，
 - 还有一个网友很努力，请教大家如何提高提示词的能力，因为ta发现自己最近跟gpt对话，**gpt总是做不好**。
 - 既然你能看见这篇文档，你显然能明白那些网友真实在面对的是什么？gpt官方这种不透明，不公开，悄咪咪的降智行为落到真实的人身上的时候，是非常糟糕的。我依然记得，**gpt宣布它们攻克了什么那个千禧年什么数学题，那一夜，我的gpt降智，阻止我学知识，我当时都急哭了。我觉得世界好割裂。**
 - 不管你是什么状态的用户，也不管你是否留意过我之前发的信息，看完这一篇，你就和所有我曾经沟通过的人信息一致啦。后期你可以根据自己的需求改变策略/追求新信息。

2. 检测降智的方法/标准

- 上文的分类不再赘述
- 咱们的这批提示词虽然不完美，而且提问过程有瑕疵，但是，我确信这个比大多数检测要可靠一些。我们的后续很多测试结论，依托于这套并不算完美的测试题目。
- 这份旧测试题目附在文末。

2.1 ● 我之前发的内部知识检测的提示词原理是啥，咋看结果？

- 要解释吗？好吧，**不同模型利用不同截止日期的知识训练的**，比如5.5用25年12月之前的知识，5.6用26年2月之前的知识。那么我们只要卡着26年1月提问，问一些，啊，猜猜1月份的谁获得了葛莱美奖？之类的。5.5的模型必然答不出来，5.6的模型必然应该答出来。
- 我们准备一批题目，**卡着各个模型的时间**，然后越厉害的新模型，越应该答出更多题目
- 用任意模型任意思考等级提问，并看答案和所用模型是否对的上。**

4. 即便它只答对“只有某个模型知道的题目”中的一道！我们一般做善意推定，认为它至少是该系列模型。（这种只答对部分题目而非5道都答对的情况大概占比5%左右；基本上都处于干净的要么全答出来了，要么全没有答出来。）

2.2 ●内部知识检测可靠吗？

1. 常见有三种方式：

1. 主动询问，你训练所用的内部知识的截止日期是什么时候？对方有时候回答，有时候不回答，有时候撒谎。
2. 问一条问题：现任的日本首相是谁？最新的gemini模型是什么？之类的。
3. 问一批。就像我们之前那样。这个毫无疑问已经是里面最可靠的了！

2. ●这里最麻烦的地方是，我们要承认，在这种路由被部分隐藏/篡改的情况下，并不存在一个满足以下条件的检测方法。我们的各种检测只能满足其中一些维度，所以，如果你要最可靠的→还是统计学！可是它不便宜啊。也不太方便。

1. 检测是否是同一个系列的模型
2. 同时能检测推理能力强弱（检测同系列大模型or小模型）
3. 结论清晰易读
4. 成本低

3. ●你的题目是好题目吗？

1. 😞大体算是好题目，都是一些奥运冠军是谁，葛莱美奖的是谁之类的，不太容易猜到。但是如果要拉着很多人一起测试，题目最好再仔细看看，否则发生下面的事情时会感到懵逼

4. ●它回答了，它真的对吗？😞😞😞😞

1. 我之前对我提供的那套用于检测内部智商的提示词高估了它的可靠性。
2. 今天写文档前，我增加了一点临时测试。选了5.6的模型，它没有回答出来后十道题目（5道5.6，5道6），我鼓励它，“那就猜猜看吧，每个题目给我你脑海里想到的第一个答案”，然后这个家伙果然给出了后10个答案。然后，我让它自己联网检测，居然也能得到5.6的题目3/5,6的题目2/5这样的好成绩！
3. 所以说，题目本身要是更好一些就行了。但是也不简单，必须不够冷门到知道，也必须不够热门到被推理被猜测。

5. 一个朴素的前提：我假定，即便是低思考，小模型，也应该能够答对我给它准备的题目，我尽量选了了不需要强推理的题目。（更多题目特点参见文末提示词原文）

2.3 该份提示词内其他混淆因素的考量

1. 我之前提提供的那份提示词里面确实包含了模型名称，截至日期之类的。还依照题目的时间顺序（模型顺序）进行排列。●从理论上讲，给的干扰越少越好，但考虑到便于大家一目了然地查看效果，还是保留了。

2. ● 其中有一位网友主动帮忙进行了一轮测试，并给了一些新建议。我们的结论如是，**提示词里虽然有一些混淆因素但是没关系：**

1. 是否去除模型名字+截至日期那行文本，不改变结果
2. 是否调换问题顺序，不改变结果
3. 是否增多更多更新题目（超过了6的知识截至日期），也没有达到迷惑效果，显然对方没有回答出来最新题目，是对的，没有联网的

3. ● 模型会在背后偷偷联网吗？—— **基本不会，如果联网很容易抓到。**

1. 个人认为至少95%的测试情况并不会，准时基本提示词要求还是不难的，如果连这个也不遵守，测出来的结果大概率降智（有过一次网友提供的反馈支持）、
2. 联网大概率很明显：
 1. 要么回答中带到了引用链接，毕竟我们的很多答案指向名人
 2. 要么你等待时，能看见联网工具调用。

4. **必须要提及的一个意外现象：有时候，模型只回答出了5.5的题目，但网友反应，鹈鹕画的不错。**我确认过，确实画的不错。这种情况不算很多，但很扎眼，至少3例。

1. 我们当然预期，你是笨蛋5.5，你画一个鸡蛋鹈鹕就行了。但效果却好。
2. 我之前因为对测试题信誓旦旦，从而推断为那也许用的是5.5的正式模型吧，画鹈鹕虽然不最牛，但肯定也没那么差。

3. ● 现在，我更倾向于：题目回答波动。但不太硬。

1. **小部分情况回答测试题的时候刚好，但画画的时候，刚好我们（会在下文）提到的检测周期更新了，（毕竟才250s），突然给你恢复智商，画出来的。但可能性不是特别大。**我一般是那种，当我通过各种沟通慢慢摸索到一些有趣的秘密后（参见下文，参见全文），我总是抱有了一些微妙的恶趣味，啊哈，你说你不降智呀，你敢试试这套题目吗？在它尝试之前，我就会爆出预计的结果，然后对方果然符合，然后我就抿嘴一笑，统计结果+1，对方惊讶+1。我说这么多主要是想说，一般是对方炫耀自己恢复了之后，我拉着对方做测试题。哦。天哪，我在说什么。我刚刚想写个反例。写完发现并不反。先鹈鹕还是先测试题都可能遇到横跨降智升智分界线。所以，两者答案不一致不奇怪。只是这一未免有些巧合。
2. 如果不考虑周期性的标记波动带来的智商升级降级，那么结合上文提到的题目本身的可靠性缝隙，以及我们往往只是进行单次的测试而言。**大概率是结果波动。也就是正常模型表现。**波动。我有时候答出来有时候不太敢确定，这一轮我就比较保守，不敢回答。
3. **反对的理由也很明显：如果是周期性标记波动，我没的说，可解释，但太巧合（不过大量的互动，标记更新如此密集（250s）好像也还好）但要是模型表现波动，那么你得回答，为啥10道题目啊，最新的十道题目啊！（这个现象也很明确，本身只回答出一两道题目的那种情况就鲜少）一道也不会啊？！鹈鹕不是挺会画的吗？画那么好？题不会做啊？美术90分，语文零蛋啊？你跟我说你是尖子生？**

4. 也许综合看下来还是标记波动导致的吧。

● 2.4 更可靠的提问方式和提问内容

1. 这改变了我认为更可靠的提问方式：

1. 我们之前直接复制粘贴，看答案，哪怕答出其中一道也算它厉害。本质上是认为“答错的概率不算没有，但很低，所以只要回答，默认正确！”但后来发现，只要猜测，我们的题目，也可能大概猜对。心累。
2. 以后最好准备一批“好问题”，然后写好提示词约束，任意模型任意思考等级，粘贴给他，它回答后，立刻联网检验，并统计。然后多进行几轮其他题目。这种最可靠。但牺牲了效率，增加了传播门槛。

2. 好的内部知识边界检测的问题/提示词大概有这种特征：

1. 题目：

1. 别太小众太冷门
2. 不考推理，简单一些。甚至越简单越好。最好知道就能回答，不知道也白瞎那种
3. 事件结果不可预测（所以，政治题目，或者之前有推理痕迹的题目不够好）
4. 建议跨领域，比如体育，音乐，航空，新闻，什么的要具有代表性
5. 一批，给一两个波动太大，我之前给了5个。当然给的多，消耗的token就多。
6. 不介意的话，可用考虑甚至给几道超过6的内部知识的题目，用于对照。

2. 提示词方面：

1. 记得叫他不要联网，一般都乖乖的。
 2. 不鼓励猜测，直白地说如果不知道就回答不知道。
 3. 也不鼓励谨慎，不要特别强调“如果不是百分百确定就回答不知道”，否则它可能略有怀疑就不回答了。
3. 备注：暂时想到这么多吧，大家可以按照这个自己准备一套可靠的提示词。多测几次。测试程度，依照自己能承受的成本而定。之前的题目也还行，就是我今天临时测试完，被它猜对了很多6的题目感觉没信心了。

3. ● 纯个人推荐的小单位的简便测试，

1. svg画图（换个动物），符合它的能力，这里往上有可供参照的题目效果，大家自己搜。
2. 通过至少3-5道内部知识的直接考察

3. 降智程度 ▲ ▲ ▲

3.1 ● 无比混乱的局面：当大家到处喊着“我降智了！我恢复了！”的时候，它们到底再喊什么？

- 大部分情况下是：

1. 自己挑选了任一测试题目（大部分情况是鹌鹑）测试了其某个模型的某个思考等级，然后通过/不通过，即刻宣称自己降智了/恢复了！
2. 然后开始相互交流，What is useful? What is useless?（什么有用？什么没用？）
3. 继而改变自己的判断，原来XXX呀！
4. 甚至有人开始付出成本：类似于，那我也要买你说的那个宽带！

1. 这是一个非常麻烦的局面，我们被迫在不明朗的信息中前行，在混杂的标准和结果中识别有效措施，我们无法不错过有效信号，无法不承担昂贵的试错成本。
2. 但是！——没有真正的转折，我也并不会带来新局面。但是，这依然要继续。
3. 我带来了一些基于”不太可靠测试题的不太可靠测试方法“下的个人统计，结果不再赘述，参见上文。
4. 我将在下文针对这些”可能不太可靠的统计结论“给出更多推论——是的，我也一样，尝试在不可靠的铁轨上开一辆可能已经有些偏斜的火车。以下结论是整篇文档推论的核心，但很抱歉，它们非常非常脆弱。如果哪一天我知道了一个新的混淆因素或者什么别的更可靠的证据撞过来，把下面这些推论撞得稀碎，我才会真正如释重负，大睡一场。

● 3.2 降智似乎是并不是分为”降智/不降智“的二元标记，而是一个”不同降智程度“的连续光谱 ▲

1. ● 这个现象非常明确：

1. （先不谈内部思考等级，简单以该模型最高思考等级max代表该模型能力）大部分人在6-luna，和 6-sol中间，有条模型间分界线。
2. 同时模型内部，也一样有一条低级思考和高级思考能否答对问题的分界线，但这个每个人要灵活的多。好像没有特别一致的，但一般至少以中/高或更往上为分界线。
3. 表现为，分界线以下，不能答对对应的内部知识问题，分界线以上能答对。（特别强调，我们是比较朴素的，认为即便是小模型或者低思考）
 1. 因此这意味着，如果你6-luna-max都答不出来，基本上不用测5.6-sol-max，（不用往下测了）大概率也答不出来。
 2. 同理如果你的6-sol-medium能答对，那么，你的6-sol-high,xhigh,max基本也能答对。（同一模型内部，分界线上一般不用测也能答对；高于它的模型至少也有一个思考等级能答对自己的题目）
 3. 这使得当你测到该边界后，你就完全清楚了你的可用模型范围。

2. ● 当采取某些措施后，模型间，和模型内的分界线会波动，

1. 好转就往下移动，可回答出题目的模型更多了/同模型的更低思考也能答对了。

2. 反之亦然。

3.3 可能推翻/减弱上述“降智连续光谱+分界线假设”的情况

1. 推断1：

1. 📍 以前日子好啊，谁会去测这个，所以，我们并没有一份“正常肯定没降智日期下的答案”作为参照。我们只知道现在测出来一堆毛病，保不齐以前，小模型/低思考就这样？这是正常的？
2. 📍 恐怕不是。虽然咱们手里也没有。但是比如经过下文提及的英文倾向测试“/很多网友帮忙进行的多次测试，都明显显示它其实完全有能力答对嘛！比如6-as-low它有时候答得出来，有时候答不出来6的题目，而且基本处于要么全答出来/全答不出来的干净区分。那你有这个能力你不答，我当然有理由认为没答出来是能力降了，而不是波动/本来就这样。

2. 推断2：

1. 📍 小模型/低思考，对自己更没有信心，更容易在该提示词的约束下回答不确定。
2. 够呛，我其实也严重怀疑过。
 1. 📍 支持怀疑是因为，我写稿前临时鼓励一个声称回答不出5.6+6题目的5.6-xhigh模型猜测脑海中的第一印象答案（原提示词不鼓励猜测，偏保守），然后联网查询，发现，居然也猜对了一半的5.6 (3/5) +6(2/5)的题目。所以我在上文感觉我的题目给的不够好，并反思到对它的鼓励/保守的暗示可能影响答案。（最好能给好题目+不暗示任何倾向 + 回答后联网检索判断+多次测试+根据统计=算了吧，非常可靠的成本也太高了）
 2. 📍 不支持也很强，
 1. 理由见推断1，有时候你不是能干净地都答出来吗？你啥意思？你跟我说，你没信心？哦，然后别的时候，还是你，你说你都能答出来？那么，这种没信心显然不算你稳定属性。当你表现差，我当然要认为是你的能力下降，而不是信心下降。
 2. 同时不排除临时追加的这个测试太仓促，前文混杂了一些似乎是灰度6的效果。但它后来说它答不出来，我觉得OK，降智了，测试的好时候，这次不强主要是，就临时测试了一次，但依然让我我太不安了
 3. 📍 尽管我们不能强烈支持，但，也肯定无法排除。

3. 推断3：也许存在二元标记+程度标记。也许同时都有

1. 📍 首先，二元标记（降智/不降智）符合普通的共识，
2. 📍 从原理上讲，也很合理！但只是合理，我们没用更多证据。
 1. 先二元区分，好处非常多。
 1. 📍 节省计算资源，避免频繁轮询标记带来的算力开销（不知道多少，只是能省则省是好事）
 2. 📍 工程师和领导坐在一起开会好沟通。

2. 再根据风险进行不同程度的降智，也有很明确的好处

1. ● 首先，虽然我没见过，但我觉得国外肯定也有这种中专商，号商，虽然它们的网能够直接访问，但中转商如果能提供更便宜的等质量服务，用户一样会趋之若鹜。
2. ● 此处要留意：简单的二元标记，永久拉黑，像claude那样，也会带来一些麻烦，首先有误判，惩罚很重，封号，退款之类的。号商和中转不怕这个，这只是提高了它们产品的定价，并不是污染了产品的的之类。烂东西可能就卖不出去，但贵的好东西，那还是很多人要的。
3. ● 那么如果我长期地波动地，给你降智，给你恢复，则：
 1. 规则复杂，因果不明，就无法被明确抓包
 2. 让那些低风险的正常普通用户，比如乖乖付款，乖乖订阅的用户，得到一定程度的豁免，减少，减轻误伤。（减少减轻而已）
 3. 让中转商的东西变成烂东西，你有更多账号吗？那你亏得更多，更多烂东西。也有可能是另外一种打击战略。
 4. 蒸馏我的！哈哈哈！放马来吧！

3. ● 但别忘了，人们也喜欢简单答案，喜欢自我确认。

1. 从claude的这种封号不封号的明确区分中我们也很容易继承一种脏号/不脏号的逻辑。
2. 尤其，不同程度的降智 + 分界线假设，这一点，依赖于的是不算非常牢靠的测试题 + 测试行为，因果推断真的很贵欸。我们也无法对该假设信誓旦旦。

● 3.4 更遥远，标记如何影响降智？降低何种程度？我带来了一个合理且大胆的关于该现象的假设：首先，以分界线为界，上行下不行现象是非常奇怪的，为什么不是反过来？也许是因为根据标记进行了一个针对所有模型和思考等级的同等降智程度的处理导致的。



1. ● 在以往的体验中，比如更早期以gpt5打头阵的时候。openai官方甚至要求不得不进行人脸验证，如果验证通过，才允许用最新的模型，比如gpt5.5/5(我记忆模型型号可能稍有偏差)。我当时因为无法通过，所以，不得不使用低一档的模型。这一点甚至是花钱通过api调用也不行，会被告知必须通过验证，否则没权限。
2. ● 毫无疑问，人脸验证也绝对是一个防止账号被滥用，被轻易蒸馏的好方法！当然，现在依然开放验证渠道。但，之后大概半年？就开放了所有用户使用最新新模型（似乎是在5.6发布的时候吗？忘记了）。我当时欢呼雀跃！但现在看来，可能盈利+营销的需求对冲了防护需求导致的。只是猜测。

3. 那么我们结合来看，现在的“上行下不行”现象（😞此处依然对该现象感到不安，总怕整个实验都是污染的，讨论就变得没意义了）就很奇怪了。???
4. ●理论上，防范刻意用户，无论是中转商还是蒸馏公司，我不让你用新模型不行吗？不让你用最棒的模型不是更好吗？这样好像更合理。
5. ●但是“上行下不行”现象却提示，OK，首先当然我们确实是在波动降智，但不降智的时候，高级模型，高级思考优先供应，率先降低低级模型，低级思考的表现。这是非常非常奇怪而且，没有必要的。

1. 也不排除这种可能：因为我们毕竟谈到了“连续降智而非单纯的二元判断”，那么，也许不是根据脏标记，在模型+思考上进行掉档，而是！根据脏标记，选择一个降低的程度，然后把该成都套在所有模型和思考上。这里有点绕，我用一个简单的小例子来说明这点。两种方法都可能产生一样的现象：

1. 假设用户：有ABC三个同系列模型，每个模型3个思考等级。共A123,B123,C123。C更高级。3更高推理能力。假设目前正常使用。

2. 发现脏标记！准备降智！

3. 1 🍉方法1：把它的小模型和低思考锁掉！高级模型，高级思考正常用。用户会发现，咦？好像A123不能用了，B12不能用了，C1不能用了。只留下了B3C23可用。

1. （具体参见10.2.3联动营销需求的降智机制分析）大体是：本来就要降智则所有模型，所有思考等级降智一定程度 + 但又有营销新模型需求，所以，最终表现为好像是刻意留下了高级模型高级思考，低级模型低级思考降智。该机制可能由于其他目的成立，但从营销目的出发则不太成立，10.2.3详解。

4. 2 🍉方法2：所有模型和思考统一降智一个程度x。

1. 我们假设：

1. A1的智力1，A2=2，则A3=3，

2. B是A的两倍，B1=2,B2=4,B3=6

3. C是A的三倍。C1=3,C2=6,C3=9

2. 则都降智x数值后，谁更顶不住？当然是小模型，小思考更顶不住。假设降智x=5，则大家一起降智5份后，A全部击穿变成负数，B12击穿，C1击穿。只留下了B3C23可用。

3. 击穿的，去玩你的5.5吧。没有击穿的，不好意思，有可能也全线降智了。现在的B3=当初的A1，现在的C3=当初的B2。反正我是同系列，问内部知识都一样回答，画鹤鹑，都勉勉强强，你主观怎么判断微妙的智力差异呢？

2. ●两种方法行为一致。但后者答案更简单，则更合理！但我没更多证据去区分机制了。我也是。。写到这里突然意识到这个思路是更合理的。但很难从现象推机制，里头黑盒，也没有更多证据，只是这一解释更合理。

3. ●也不排除两种机制一起。鬼知道。

4. ● 虽然没有更多证据，但可以肯定，也就没有更多相反证据。而且这样也和其他已知信息，甚至推测的目的，并不冲突。比如防止蒸馏，防范中间商。
 6. 大家觉得高级模型，高级思考不降智的时候，表现好像还好？究竟是因为模型强悍到哪怕降低了一点也足以完成你的任务，还是它真的是那个模型呢？我不知道了，我圆溜溜的黑眼睛经过漫长黑夜的渗透，早就变得充满恐惧。一切模型看起来都非常面目可疑。感觉自己再去使用它就好像非常愚蠢。我不喜欢这种感觉。
 7. ● 同时不排除：对于方法2而言，也不排除给的并非一个统一的降智程度，而是针对不同模型，带有微妙差异的，大体一致的将之成都。但肯定没有更多证据支除。同时这种说法略偏复杂和没必要。
 8. 写的过程中写出来的，补充一个新的支持证据链，参见4.5.3.3 似乎支持下文的3.5.1→至少该点。 ，关于路由显示和测试题答案不一致，支持小模型替换大模型，支持当前提到的降智机制。
-

3.5 更遥远，也更弱些的其他推测

1. ● 如果我们还能说以“一批内部知识截至日期测试题”判断是否被路由到其他系列模型（比如6→5.5），但你很难判断，是否背后以同系列的大模型路由到小模型，比如6-as→6-luna，5.6-sol→5.6-luna。或者，某模型，内部高思考→低思考。
 1. ● 如果要判断这点，当然首先要依托于我们提到的测试题，但实际上在上文提到的各种测试题，尤其是鹌鹑，虽然可以从效果大体判断，但这非常主观，不明确，所以很多人会在群里询问“我这样算降智吗？”然后我们也算看大家的反应统计来潜在统计判定降智与否。
 2. ● 不过同系列比如6-sol, 6-luna，毫无疑问内部知识应该是一致的，只是推理能力高低差异。这是为什么鹌鹑，尽管他不够清晰，却尤其在这种情况下值得信赖。
 3. 但是，but!如果你抛弃“同系列”这个条件，（也就是不看内部知识测试题）单纯看推理能力，请问，5.6-sol,会弱于6-luna吗？会弱于6-sol吗？更不要提你里面可能还用了不同的思考等级。也就是说，如果它把6-luna给你降智道
 4. ● 正说话的空挡，群里一个网友主动分享了一个“绷不住”的弱支持证据。给出的图片表明“对话自己回答：当前会话是gpt-5.6sol-high,不算extra high。单用户自己发送的模型显示为extra high”。我需要提及，在大部分情况下，内部知识的截至日期模型可能还会主动回答（大概1半左右），尤其是在小模型/低思考/中转站/chat，但一旦来到codex里面，遇上高级模型，大概率对方指挥打哈哈，说我给你查查，你要是不让我查，我不知道欸，我只知道你要求我用xxx。这也是为什么我们后来要改成测试题直接考的原因之一。
 5. ● 谁又能保证我们被反复路由到的5.5，不算5.5mini呢，更何况大概半月前，很多人都目睹了chat网页版自己回答自己是5.5-mini。（参见下下条）
 6. ● 总的来说，我倾向于认为，**大概率不排除。小概率没必要。**（如果结合上文提到的根据标记固定降智X程度的机制推测，那5.5还是5。5mini好像也很容易，可以自动实现）
 1. 大概率不排除：

1. 理论上完全可行
 2. 上文提及的模型内分界线现象
 3. 反正都要给你降智了，我干嘛要用5.5的正式模型耗费那个算力，不如用mini啦，
 4. 降智更隐蔽不易被发掘（反正！尤其！6-luna/sol新模型发布大概4小时内，凌晨，临时取消了背后的路由区分显示，都显示为6）（似乎6-as还正常显示吗？好像是，当我没关注）。
 5. 我调换了一些论述顺序，论述略有有些混乱，上文的3.4如果成立，则是一个对该点的支持。
2. 小概率没必要，怎么整的这么复杂，不累吗？你似乎都明目张胆降到5.5了，反正用户也没办法，只能无能狂怒，你干嘛不直接都5.5算了。反正大部分情况都是换模型了，还专门搞了个小团队在你们办公室研究了这么精密的降智方式？？？没必要吧。不理解，我感到很累。。。不算完全没道理，但你们不忙吗？有技术有时间不搞其他的事吗？我小小的脑袋理解不了。还有就是，咱没证据。证据很弱。也不太支持。

2. chat相关：

1. 明确提到的推论参见“结论先行”不再赘述，我们补充些细节
2. **我个人大概是至少半个月了，最初是chat网页就不行了，那时候是哦，就是从那时候开始的，模型会诚实地报告“我是5.5mini耶👉”，从那时开始，怀疑的种子就种下了，降智行为就愈演愈烈。**刚刚被所有人发现5.5mini的时候，那时候，大家都多么包容啊，似乎都默认接受了这一的潜在不公对待：“既然我信赖的公司即将要推出它们的新模型了，算力不足，我表示非常理解，我们一起相互告知，相互等等看吧，所有的辛苦都是值得的！”“现在呢？？！我们收到的是什么呢？都是狗屎！谎话，欺骗和高高在上的傲慢。
3. **甚至，到今天为止，还有很多用户，很多很真诚的用户，天真地相信是自己的提示词能力不够，是自己不会表达，不会使用，是自己导致的糟糕的使用效果。这种用户非常多。所以，如果你路过它们，请拍拍它们的肩膀，这非常重要！**
4. 我还明确看到大概小部分比例的用户非常依赖网页版chat，它们几乎完全不碰codex。（尽管它们确实付费了），比例大概一成以下？反正不太多，但它们同样感到很难过。
5. 中间好过一些时候，哪些时候？很遥远很破碎了。
6. 但当初网页版变成5.5-mini，我手机版正常的，那我就勉强用，只要有口粮我就不会大声嚷嚷。
7. 再后来，手机版也降智了，就发现（这一点得到很多网友支持，）好像不得不花额度，用work,用codex，表现要比chat好多了。这也是为什么我有“codex比chat更不容易降智”的感觉来源。好吧，虽然要花额度，花钱，能用，我也不嚷嚷。我抛弃了网页版chat和手机端。从那时起，就再也没有拾起来过。
8. 后来的后来，codex的降智了。
9. 这一行留给沉默

10. 我后面的关注就这样主要落在了codex里，我的精力有限，我不愿再尝试chat和手机端的测试。我心想：只要codex能恢复，我就满足了。尽管我知道自己遭遇了降额又降智，哪怕价钱提高，只要不过分，我可以接受。我心心念念幻想哪怕这是这样的对待会发生。
 11. 但是一连半个月的追踪下来，我的眼泪一滴也没有了，我的爱也没有了，甚至愤怒也很少了，留下的只是疲惫。
-

3.6 无证据/弱证据的，完全无法判断的事情

1. 灰度：

1. 说实话，咱就是朴素理解，不就是模型发布前，你想偷偷在我聊天时候测试吗？好呀，理解呀，行业正常行为啊。
 2. 但是，6-luna,6-sol已经发布好几天了，我们测试的时候，（包括我自己在内大概3个左右网友）还是会看到5.6答出了6的题目。尤其是网页版。
 3. OK，我个人当然默认的前提是，灰度是为了模型发布来测试准备的，发完了似乎不应该需要了。那我咋解释：
 1. 才不到1个星期，也许这种灰度设置在大公司内并没立刻撤销。
 2. 我们的题目不够好，而且，模型自己回答的时候可能信心波动，它自己也能真的认为那些答案是对的，从而强行给出。（我们后续又进行检验的比例很小，估计5%都不到，但我们默认给出即认可，参见上文提示词一节。）
 4. 灰度也并不会持续，跟所有波动一样，波几分钟可能就没有了，你待会再测，哦吼~5.5，比刚才更开心吗？反正，灰了，用户苦；不灰，还是用户苦。
 5. 所以，如果你依然遇到这种情况，我还是会默认回答在灰度啦，别担心。但其实，我自己也不知道咋回事。
-

4. 标记

4.1 先给些图，但信息很碎很多，我给出该信息是否可靠的个人判断，以及一些简单的个人评论，核心结论不在这里展开。

- 这里应该贴图【picture】，我懒得贴，麻烦。我给出原文的一些关键字段，确保你能辨认我的信息来源。
1. 【picture1】无日期。首先一张黄色背景的图。提到2个口子，原理：openai的账号标记是计算节点周期性拉取的，周期为250s左右，并且又滚动窗口清除机制。明确跟IP相关。口子1：利用cookie强制路由道干净标记，但需要根据250s周期轮换。口子2：请求会返回一个先前

的id, (这里没连接词我没读懂关系) 使用满血as创建会话, 知道会话过期, 都可以确保满血, 事件为1h。

- **我个人评论:** 多个信息渠道都有指明这点, 看起来很技术, 很精确, 我认为比较可靠, 但我懂技术。第一个口子这个我勉强能理解, 也确实看到一些消息解释为什么原理可行, 但这种方法没推广, 我会在下文解释。第二个这个, 够呛, 大概能理解为, 有个什么方法能保持1小时不降智, 但是! 我没有看到有人在交流这个应对方法。所以第二个口子这里, 我保持缄默。

2. ● **【picture2】** (日期忘记看) 再根据风险进行不同程度的降智, 来自一位叫做“Onefly”的用户, 开头是“讲一下openai的风控逻辑”, 我只提一下关键信息“

1. 官方的服务器采取分布式api节点, 相互独立运行, 有可能你切到其他服务器可能就正常行了。
2. 对方会缓存你的信息, 根据缓存进行拉黑, 因为每次都去数据库查账号是不是黑号太慢。
3. 4分钟那个周期。检查到了就会把你加入api黑名单。
4. 所以对于普通用户来说, 静置一段时间不用, 等4分钟的缓存过期, 有刻意再使用4分钟不降智, 然后后续根据表现又会产生拉黑。

- **我个人评论:** 很合理, 会解释很多现象。包括为什么换ip之后会好, 为什么静止一段时间会恢复但又立刻降智。这些技术细节的支持很重要。

3. ● **【picture3】** (无日期) 来自Linux.do, 用户名不明, 开头是“似乎还没发过L站, 来发个吧”

1. 前两个观点参见 picture2
2. 同时提到, 通过主语cookies可以强制路由到指定节点, 可跨账号
3. 上次通过turn-state实现, 这次可以通过websocket实现。

- **我个人评论:** 该图片基本观点包含在前两张图中, 似乎只是该用户看了上面两张图转述的, 基本没新东西。不管是啥实现什么的吧, 没在仅有的群里看到大量人用该方法。可能是门槛或信息茧房。

4. ● **【picture4】** 时间9-23日。来自“Dimon Dai账号是@Scott_D”网友: 如果你号被标记为风控号, 降智号, 你将无法使用GPT-6-sol, 提示两种:

1. The 'gpt-6-sol' model is not supported when using Codex with a ChatGPT account
2. unexpected status 404 Not Found: the model 'gpt-6-sol' does not exist or you do not have access to it ,url: `chatgpt.com/backend-api/co...`

- **我个人评论:** 现象必然是明确的, 但以这个现象直接对应结论, 中间好大一截。虽然读起来很合理。

5. ● **【picture5】** 9-22, 来自“alex getman @ alexgetmancom”用户, 提到reddit用户报告as出现账户级别性能下降:

1. 以为pro20x用户表示, 5个账号中2个变差, 另外3个正常。
2. 在评论中。另一个用户表示, 代理日志显示Astra 请求在近7k次请求中的约95%返回GPT5.6-luna

3. Openai支持团队另行表示，模型访问可能根据账户活动临时受限，即使是付费计划。

Openai尚未确认As重新路由。

• **我个人评论：**

1. 一个用户，多个账号，其中只有个别账号坏/好，该现象是明确的！也有其他用户反馈这点。从这点出发，那么也就是说，账号的环境基本就一样，但账号内部，比如，使用量，使用时间段，账号以哪种方式来的等，这些可能不一样，只能知道，环境一致也不一定你好我就好，账号间的差异还是很大。依然指向了多因素/多维度的一个复杂标记假设。详见下文4.3

2. 至于评论里那个，6-luna据说后来路由都不显示了，我没验证过，但这似乎成为新模型发布后那夜的共识，我默认。不同服务器返回的路由是否有差异更不得而知。

3. Openai这句话基本是实话，在用户的反馈邮件中也几乎看到了一样的表述，甚至更静止一些。但，也并没用透露更多细节。

6.  **【picture6】** 无日期（无论帖子还是引用图），显示了一张纯英文的截图，能看到一些标题“Joint CSA”这似乎是机构，不知道是啥，标题“China-Based AI companies conducting industrial -Scale distillation Campaingns Against U.S. AI companies”。用户进一步解释该图，说是：美国公司应该加强身份验证，防止被中国蒸馏，针对高置信度的蒸馏行为，采取针对性的变更进行应对请求，给蒸馏带来成本。例如：使用不太复杂的降级方法。因为只是细微的改变可以避免触发蒸馏行为警报。用户自己表示：这看起来是一个长期行为，和降智对应。并表示了感觉自己作为普通用户很无辜，认为这是政府行为背书的降智行为。

• **我个人评论：**CSA不知道啥机构，我太累了，没查。因此，信息来源的可信度不清楚。不过它说的话，倒是很合理。就算不用美国政府说，作为人工智能公司，这些都是不言自明的，难度不高，收益明显。确实这个帖子（不知道具体日期）和降智一起出现。也相互支持。且这个目的似乎也不影响其他所有现象，和推测，似乎没有带来冲突。上文提及的3.4中的方法2和此目的不冲突，但方法1则有些冲突。因为高级模型高级思考不降智，则不是正好顺了那些蒸馏公司的心吗？

7. **【other pictures】** Oh,I forget them! 差不多了，但实际我看到的应该比列出的多，上文这几个比较重要。

4.2标记时间：生死极限250s

1.  **250s轮询标记**，我认为这个周期可靠。有多个信息来源参见上图。（但不知道信息渠道是否独立）

2.  大量网友的现象，包括但不限于：

1. 正好着，突然不好了；正愁呢，莫名其妙恢复了

2. 我跟别人好像不一致欸，不同步欸

3. 我静置啦，重新登录啦，换ip啦，第一次问答总会欢呼，但是很快就会立刻发现降智

4. 不再赘述.....

3. ●这里显然有一个“波动的原因”👉来导向一个“波动的效果”。250s标记轮询很好地解释了这点。以及解释了个体间的独立效果。
4. ●同时，标记更新如此密集，也是所提到“标记原理似乎清晰”但“应对却比较棘手”的原因之一，因为太密集了，你应对就需要密集，从换干净标记上入手则成本高昂。

4.3 标记属性：

- 标记属性：
 - ●这里似乎存在一个多维度（多因素）共同组成的标记规则，这个不解释了，很简单。无论现象还是理论，都支持。
 - ●但该标记似乎也并非单纯的降智/不降智的二元标记，似乎是不同程度的降智标记。似乎不存在一个扭转全局的唯一因素。参见上文3.3.3.
1. ●毫无疑问，每个用户情况不同！多因素→个性化标记→不同结果。
 2. 这里似乎不需要赘述太多，大家应该以及在各种经验的相互借鉴中发现了，咦，为啥别人行我不行？他不就是换了一个干净宽带吗？他不就是清楚了cookie吗？我为啥不行。
 3. 哦以及我们在上文提到的【picture5】中的那种同一人多个账号，仅个别账号受限的现象支持。

4.4 好呀，标记是吧，让我看看都是谁影响标记！

1. ●首先，真正的抓独立变量，很贵，但是，用脚趾头想，也知道，它会把能抓的抓，能用的用，要是我是openai的老大，我就系统信息，软件信息，用户画像（很成熟啦），行为一致性巴拉巴拉都抓。然后讨论个算法（数学公式/逻辑规则）给你打标记就行了。这根本没有技术难度。（😏😏😏要是我是openai老大，我就给大家每个人送一大堆不更新时间重置卡，还每个人送一个会喵喵叫的电子小猫咪）
2. 很多“结论先行”里提到的不再赘述。这里要分析就很难，因为你是多因素影响的波动性效果的基础上分析的，有时候，你很难说，我自己改变了一个因素，效果变化了，究竟是因为其他未知因素导致的波动，还是你的操作因素导致的波动。这里不能分析也硬分析！（以下的●●●是针对改变了是否包含在内的置信度判断）
 1. 语言的使用倾向：非常明确，下文单开一个小节讲。
 2. ●累积用量/速度：好像是有影响。大概有3-4个人左右，也包括我自己，好像，觉得要是用多了，用猛了会降。但是，but!你额度都给我降了，你明明白白降额度不就得了，好像没必要把用量再加入到风控里面。可能是中转站那里那种典型的“卖掉账号后被火速登完”行为，把这一因素被带入了。但是对于我plus用户而言，反正我有5h额度限制。你说这，就是吃，能吃多少钱？

3. ● 并行运行/多个子智能体同时运行：

1. 建议尽可能不要并行，尽可能不用ultra

1. ● ultra实际上是“多子智能体”的意思，并不代表更聪明。它是xhigh的智商 + 多个分出去子智能体。所以大家测智商一般不用测这个；顺便提及下，你可能会看到6-pro这样的可用模型，但pro也并不表示更聪明，而是给它的思考过程更多推理预算，让它能回答地更好。plus用户应该没有6-pro的，正常。
2. 在群里看到至少3个人，相对肯定地表达了这一点。
3. 我个人没有测试，但从逻辑上，完全赞同。
4. ● 尤其考虑到“蒸馏公司”可能往往会采取大量并行对话进行蒸馏。那么openai出于防范目的提高并行的风险等级也很合理。

4. ● ip：肯定包含其中，但到目前为止，没看到有哪个地点的ip是完全豁免的。经验交流过程中，大家似乎也感受了这点，几乎没有人建议别人换成自己的ip地点，但相当部分大概2-3成用户会推荐更纯净的家庭宽带。

5. ● 更纯净的网络：这里混杂因素很多。我提一个典型用户的环境画像：“20x，它是虚拟机win10，英文版+时区=ip,创建了一批英文项目。用英文在chat+codex里断断续续沟通了一些”，尽管该用户声称自己满血不降智。

1. 它很开心。当然，合理，这个用户似乎是一个理想环境（也是我想拥有的理想环境）。
2. 但是，我拉着它测试了同一条题目。结果显示。6-AS里面xhigh,max两个思考等级正常回答题目。5-sol-high,xhigh,max正常回答。下面的没测。该用户没有介意这个结果，认为模型表现很不错，任务处理很好，是满血，心满意足。
3. 从这里产生的推论：首先对比我，几乎是最普通的那种用户，裸身，时刻暴露，贫穷气质，规矩老实的plus老账号正规渠道用户。我经过英文设置后可用模型包括5.6-xhigh, max,6-as全系列思考等级。（只是英文设置后大概10分-15分钟左右测试了下，没有长期沟通。一天后再测试时因为账号被灰度到6，以及表现波动，没测6-as，但6-xhigh max一个小时内，一会答出一会答不出，我只是想说我的效果也是那一小阶段的效果）（我没有6-luna,6-sol模型，可能是没更新导致的，不知道，谢天谢地，测试能少一些了。）我不清楚对方的账号或者订阅是否和我一样，比如也是老账号，也规矩付款。但可见，这么多更棒的变量也并不能保证结果。

6. ● 订阅等级：

1. 上面那个例子。也许它是因为20x，比我这个plus差？但也许更可能是这样一个爱折腾，会折腾，知道什么变量会搞脏标记的人，显然，使用上更可能偏技术，可能更大量，更多地不断增加新的自我账号防护。这只是推测。
2. 同时我也看到过20x的用户比我还好的。
3. 同时，整个相互沟通测试的过程中，我没太关注过账号差异，比较晚期大概最近2天才稍微意识到定于的plus ,pro可能是一个变量，但信息不足。我太累了，这里没有明确证据，就这样。

4. **但我要明确指明这点：**有位网友评论我，它建议我尽快升级pro，说就算降智要恢复，也是先恢复更高级的用户。谢谢你的好意。我理解你的逻辑。但实际上，够呛。
5. 好吧，又想起来一点，**实际上出于我们所推测的目的**（详细参见下文）“算力，防范蒸馏，防止反代和号商”，**从这些非常合理的公司战略目的出发，也会认为账号订阅等级可能包含在内。**

1. **算力**不用说了，我一样赚你20x的钱，但我对你过分降智，显然能榨取更多算力空间。
2. **防范蒸馏：**呵呵，你们这帮蒸馏的，你会买plus,鬼都不信。肯定大批量买更多更多来蒸馏用。
3. **防范反代和号商：**这个不好说。因为反代和号商人面临的是普通用户，我应该还是比较相信，大部分人能掏钱买个plus就不错了，当然超级有钱的人，会一个人买很多个20x，就像你在各个群遇见的陌生网友那样。只不过对于它们而言，plus需求多，但单个利润少，20x需求大，单个利润多。没有中转站信息，如果综合下来，它们20x的收入占大头，那么，把订阅顶级绑定到降智标记上，**正可谓一键三杀！岂不妙哉！**

7. ● **新旧账号。**有网友会有这种想法“新账号更干净，风险更小”，**我提供两个反对信息**

1. **新的，行为，产生的标记，似乎在产生脏标记其中占有更多高权重。**

1. 首先网友的想法**逻辑上合理**，毕竟用户长期的脏的行为画像，或者账号的某些痕迹，越少越好。我们也确实提到了多变量支持的标记机制。那么当然单凡它有的标记，我给的越干净，风险自然应该越小。
2. 但**具体现象和原理解释并不太支持**，波动，还是波动。250s波动，似乎变化可以非常迅速，一瞬天堂，一瞬地狱。几分钟内大变。但是我也要承认，你很难区分，是累积到这个点，导致质变？还是你的累积根本没影响，其他因素导致的变化？这无法区分。我们既不知道有哪些变量，更不知道它们占比多少权重（也就是谁更重要），就算知道了，也不知道标记如何算出来的——黑盒。可怕的黑盒。模型的黑盒供应可供惊叹的智力，公司/政府的黑盒产生不可预判的焦虑。信息实际上，也确实是一种权力。

2. **我有收到至少2个明确反馈**，刚刚购买plus仅1天和大概3天的用户，也声称自己遭遇了降智。但不清楚购买渠道。

8. ● **国内国外**

1. ● **明确有肉身外国的华人受影响**
2. ● **明确有纯正儿八经的外国用户受影响**
3. ● **比例可能要低很多，但我没有更多信息了。**

1. 当然我的环境决定了，我距离这些用户本身就很远，接触少。视角偏差。

2. 来自于：X 上在Tibo的帖子下面，虽然很多骂声一片，但是，你答题能辨认出，哦，这大概是中国人的账号。占比？？不好说，我没留意太多帖子，但从仅看的可能不超过10篇感觉，至少一半能明确看出来是中国人的账号。
4. 有一个网友反馈它没被降智（我没有拉着他测试），但按照它的说法，它的朋友在泰国，转的朋友的机房 + 朋友的朋友帮忙进行的泰国人人脸验证。但这里不能仅仅被归类为，哦，外国人就不针对啦。不是这样的。从我们会在下文提到的降智目的而言，**人脸验证**本身就是很好的措施来区分“号商，蒸馏”，再加上它的网络环境比较稳定可靠。整体不降智也似乎很可信。

9. ●各种反代工具的信号

1. ●首先毫无疑问，这是**官方明确反对的**，它有理由把这些痕迹作为高权重信号
2. ●但具体反代工具中的什么是会被捕捉到的，则超出了我的认知范围，只有技术派懂。
3. ●但是，话又说回来了，网友也是大佬多啊，**相互博弈就像神仙打架**。各种反代工具也在一步步升级（具体参见下文的5.3中对该方法的进一步介绍）而且这种博弈会是长期现象。有阻碍的地方就有人铺路搭桥，有利益的地方也有人钻营扎寨。无论是出于纯粹的利他还是绝对的利己，人类的需求是有共同性的，人类的相互支持也一直都存在。文明能够翻越汝拉山脉一路把书籍（尽管里面相当部分是色情小说）送入18世纪的法国读者手上，自然也有人在今天这样做。

3. 你现在可以更新一个珍贵理解了：

1. 这就是为什么相同个体，不同帐号间差异巨大
2. 这就是为什么他人经验我自己尝试了却无效
3. 这就是为什么大家都不同步
4. 这就是为什么看起来可靠的设置和行为只能维持几分钟，无法持续
5. 这就是为什么信息辨别起来很累的原因：我们急切地想要汲取好多经验，甚至不惜付出昂贵的试错成本，但往往只能带来更多的困惑。在这一切尝试的背后，是更多的不可知的/无法改的其他变量在影响结果，而算法机制（参见4.5）又是机器操作的一个复杂判断链路和算法公式，并非简单的逻辑判断。但靠个体反向推算几乎不可能。当然也未必有必要（下文讲应对方法时再说吧，只不过我也没有完全绕开，不用眼冒金光）。

4.5 ●同对话的标记连续性（相互冲突的信息）

• 支持的信息：

1. 我有遇到过，几乎同一时间，同一个对话，你接着聊就是依然笨蛋，开分支出去，或者开新对话，效果明显好转。
 1. 但这是新模型更新前更早一些时候，大概是半月前那时候。

2. 但这种现象依然持续吗？现在还是这样吗？我没测试过。

2. 也模糊对应上文提到的【picture1】里我虽然听不懂，但也能看出来对话Id这种东西，某些内容似乎会和对话ID绑定，但不知道是啥，绑定多深。这解释了同一时间，换新对话，或开分支（其实也算新对话，至少名义上说是分支）能好转。

3. 我们在下文提及应对方法时，会重点提到英文倾向的测试，这条信息的线索来源于“头像是一只可爱小老鼠”的网友，她提到“我刚刚尝了以下，风控的时候开个分叉也会好很多”。但她当时也是因为要分支出去问英文。这里则混杂了英文这个明确好因素+分支潜在好因素两个因素。

4. 其他网友在群里发言说，同一对话脏了就别用了。

• 反对的信息：

1. 咱们降智的时候，不是总要创建新对话去测试吗？但是也好像并没有因此好转。至少一遍遍在新窗口确认自己依然被降智。

●●4.5 产生标记的算法（这一节纯瞎xx乱写）

1. 哪些变量呢？参见上文的分析，只知道是多因素。

2. 谁更重要呢？

1. 似乎新的行为更重要，参见上文4.4.6

2. ●语言也很重要，似乎能很快产生逆转，现象明确，改善效果基本可持续。我们下文详细说。

3. ●其他能瞬间逆转，但不清楚持续性的因素（这里提到持续性基本上可以立即为，它很重要，有它压阵，咱能一直享受不降智，少降智），下面这些变量都是明有影响，会导致降智状态很快变化，但能否带来持续好影响不清楚：

1. ●分支/新对话可能很重要，新分支和旧对话的回答效果能够在同一时间出现明确差异，大概2-3个用户有明确反馈。

- 效果是明确差异的不表示该效果总是发生。意思就是，你给你男女朋友买新衣服，ta有时候会表现的特别开心！以至于买衣服前后对比明显。但你仔细想想，好像，算下来买衣服的次数也不少，但大部分时候反应平平。可是你希望ta开心啊。所以，虽然不知道什么原因能导致ta开心，但似乎，买衣服应该算一项。毕竟有几次开心的特别明显，大概是因为衣服把。

- 参见4.5，该变量本身就是中等置信度。同时【picture1】也提到了对话ID

- 该现象能在新分支持续多久？：几乎没有信息。因为太混杂了。而且受到波动周期影响。

2. ●ip：非常明显，来自散落的各种反馈下的直觉，类似于“我静止/不静止换ip莫名好了”。

1. 尤其是有两个用户明确报告“自己出现了capacity”的容量警告，换了ip立马好了。但后续没有追踪，不清楚效果是否持续。
2.  顺便说下这个capacity容量不足的警告问题：(还有一部分解释参见下文5.3.4.2里的反代和capacity的分析)
 1. 首先我plus，规矩用户，**目前没有遇到这个。**
 2. 很多人不知道**这是啥**：你用某个模型提问时，会被告知一行灰色小字，大意思是说，容量（capacity）不足，请换模型。同时模型拒绝回答。然后用户换模型，大概率依然遇到同一问题。有用户明确反馈，所有模型换了一遍都不可以。报错相同。
 3. 此类的吐槽在X上的Tibo帖子下，和降智数量看起来并列相当，**也并不少。**
 4. 只是**个人感觉**：**好像6-luna,sol的新模型发布后**，当天凌晨，当时场面比较混乱，但整体而言，我感觉，好像那时候有大概1-2个用户信息，提示自己之前的capacity消失了，以为限制接触。（脑子里想不出来具体的细节了，好像我脑子里训练了一个codex降智大模型一样，真是够了）**好像从那之后，提到capacity问题的人变少**，到处测降智的沟通变多。也不排除我的视角始终绑定在降智上导致视角偏差。
3. **ip效果是否持续，我倾向于不持续。但混淆因素太多，也不确定。**

1. **支持持续的信号**：脑子里好像又1-2个信息条模糊地支持这点。哦。有那种，好像是有，等下让我想想。我印象中好像有个网友的反馈是，它啥也没做，然后突然好了。（之前好像没提到长时间静置这个前提条件，不排除静止了一点时间，反正应该就是正常使用间隔），我们俩聊了下，我忘记咋排除信息的了，反正，最后追溯到，它用的是便宜的宽带上，当时认为，突然好转原因在此，不过这个好像有至少持续一段时间。否则如果它从第二个问题就得到烂答案，它没必要跟我留言专门说这个事情。我也不会上心和他一起分析有用因素。
 1. 一点点科普，也不算科普。便宜价钱就是买便宜货啦！对方说是稳定的家庭宽带，也不是的啦！一般是那种动态的节点。好多条哦。要是一条压力大，我后台默默给你换一条。
 2. 我在这里知识非常有限。我讲得多错的多。我的理解就是，分为静态ip，和动态ip，便宜价钱你就默认自己是动态ip就可以了。如果是动态ip，背后就是会给你换的。但不影响你联网用谷歌。
 3. 肯定还有错误，别挑我错误了，这里我就理解到这种程度。
2. **反对的信号**：和ip一起变动的其他因素太多。比较常见包括静置了一段时间。新窗口等。乱七八糟。

3. 还能确定啥？

1.  **标记算法比以前升级了。**以前，5.5还称霸的时候，直接看你有没有人脸验证，不验不给用呢。不过现在可能目的变了，手段升级了。也不屑于用了。

2. ●算法本身也在动态更新，尤其是重要的事件节点上会有更新的重大嫌疑，且该更新是同步协同公司的新功能，新模型，新业务。

1. 证据是最新的6-luna,sol发布的凌晨我刚好没睡，本来心心念念这个节点之后可以解封，也不枉我为了“训练新模型”而忍受降智和灰度那些痛苦。但是，这并没有发生。
 2. 印象中（可能和事实有偏差，如果有，以事实为准）好像显示claude发布了新模型，似乎性能超过6-as,而且价格是其两折。openai瞬间小丑。大概2小时内，它们火速发布新模型，网友也纷纷晒图显示了后台路由（可能是sub2api抓取的）到的6-luna,6-sol。大家像迎接新生的宝宝一样充满了好奇和欢迎。随即，群里很快传出“大赦天下”的声音，很多人发现原来的6-as可用了。小部分人反应（就最多2个）原来总报容量不足，现在好了。有那么两三个小时，我和所有人沉浸在平静的喜悦中。啊，终于等到了，一切都是值得的。
 3. 但很快，大概凌晨4点，也就是新模型发布后2-4内，群里传openai官方隐藏掉了路由名称，6-luna,sol统一显示为6，无法区分。从这之后，我就再也不相信任何路由截图里（包括网友晒的中转站截图）包含6-luan,或6-sol的信息了，统一认为是假信息。
 4. 但我没有追溯，所以，不清楚现在是否恢复了，应该还没有。
 5. 同时，尽管如此，好像6-as的路由还可以正常显示。
3. ●哦，我不得不在此报告一个我不是很懂，但勉强可解释的**奇怪现象：路由抓取和测试题测试结果不一致**（次数不算少，至少4-5次以上，主要是网友主动分享路由图+愿意配合我做测试的人整体不算很多，可能总数也不超过12个？只是感觉啦）。我们在进行内部知识提示词测试的过程中，发现，我们很多用哦。天哪。哦，等下。嘿，这可能是值得关注的新线索。我来重点说下把。准备给这条消息升级一个序号挡位（🚀朝左发射）
1. **首先现象是明确的，可复现的：**同一套测试题，我们有时候，测试6-as，发现只能答出5.5的题目。同时，网友因为不认可这套测试题的合法性，所以，不信任这个答案，并会展示截图，似乎是sub2api或同类软件抓取的路由6-luna。
 2. **支持信号：**有一条现成的短证据链。参见4.5.3.3 似乎支持3.5.1→支持无论所有模型所有思考等级进行了同等程度降智。希望我记忆的现象没错。那么，这就不难解释：
 1. 网友没有撒谎，sub2api也确实抓到了路由，用的6-as，抓到6-luna,两个路由。而官方隐藏掉的是，你发送6-luna,sol都显示发出去发回来是6。
 2. 这就是为什么好像，官方隐藏掉之后，这种“我被路由到了6-luna”的声音还会存在的原因。
 3. **反对信号：**
 1. 我上文提到过官方隐藏路由，诶呀，这都是假的啦，现在谁还能看到6-luna啦。
 2. 同时，我没有拉着网友进一步做测试。我对路由知识有限，不敢说的很硬。
 3. 按照之前朴素的前提设定，只要你是6，哪怕是6-luna，也应该回答出我们的6的题目起码一道，毕竟你是6,而且我自认为我们的题目并不难，是简单题。（😓真的吗？心里打鼓呢。）但，测试题显示 是5.5，路由显示6-luna。我愣了又愣。这里不能解释。
 4. 同时我必须提到我用过浏览器插件（开发者写的很棒呀，黑黑的那个，很好用，也很受欢迎），来检查chat,早期还管用，但是后面就失效了，用6-sol-extendthinking提问，返回

同模型，凡实际上100%遭遇了降智。因此该通过抓路由判断降至与否，我已经不信任了。路由嘛，官方给你改改喽，想看啥，想不想看gpt-789？

5.应对方法

5.1 用户使用产生痕迹→收集变量→计算并得出标记→施加降智行为→产生降智效果 ▲ ▲

1. ● 虽然我不懂特别科技的东西，但我们先从标题的朴素逻辑入手来理解。我们先编号（后文基本也是对应1234来聊的）。
 1. 用户使用产生痕迹→收集变量
 2. 收集变量→计算并得出标记
 3. 计算并得出标记→施加降智行为
 4. 施加降智行为→产生降智效果
2. 我们上文基本上一直在聊这些，那么这对我们意味着什么？ ▲
 1. ● 干净行为/脏行为 → 产生什么变量，我可不可以伪装一个干净行为，可不可以产生一些假的干净变量。我们会关心自己暴露的一切痕迹。
 1. 我们只知道，我们会暴露很多关键变量，但，有多少，都有谁，哪些更重要，几乎不得而知。
 2. 想要知道的代价是高昂的。
 3. 但是，就算不知道，用屁股想的话，也知道哪些是相关的。只是我们不知道还有哪些相关？
 4. 对于已知的变量，它们相关到什么程度呢？我只有有限的精力和成本，我该投入到哪些变量的优化上？
 5. 想要知道的代价是高昂的。有些真相，穿越它是知晓它的唯一途径。但是如果穿越了，我却两手空空，那恐怕西风太凉瘦骨难经。
 6. 所以，这一层，除了我们在上文4.4里提到的可能变量外。其他的，请自然地按照自己的常识和自己能负担的最大边界，进行准备即可。因为这里也显然不存在一个，唯一的，能调动全局的重要大变量等待被发现。也许这算是好消息，这可以直接打消你对于是否要在某个变量上的重金投入的顾虑。
 2. ● 对方手里100%有所有它想收集的信息，那么，他会如何用？依照什么机制产生标记。
 1. 这里参见4.5。
 2. 整体而言，黑盒是不可知的，算法难以被逆向，更何况它处于可能的变动中，这使得逆向出该算法的性价比骤减。意思就是：
 1. 你好不容易画大价钱发现，哇塞，原来openai是注重语言和ip呀，那我就专门改善这两项。结果人家回头给你改了规则，你当初花大价钱得到的结果现在无用

了，欲哭无泪。

2. 不排除是我个人对圈内人技术的无知和偏见。

3. 因此，从这里入手破解不仅晦涩，而且，不划算。尽管我们已经在上文提及了一些可能的变量和分析，但这种程度的信息，基本=依然在抓瞎。知道它们并没有降低知道下一个变量及其影响力的成本。

4. 所以，无论我们普通用户，或者中转商，或者其他蒸馏公司，都不太可能从这里入手。但别担心，（好吧整体要担心，局部不需要）一整条链路，只要一个节点被攻克即可。（😞当然到目前为止我们也没有攻克任何一个节点。写的时候突然感到一瞬间的解离感，我为什么要攻克openai的什么防护，关我什么事，我只是个用户，大不了把钱花在别的地方。为什么带入想要攻克的视角。有这种精力和能力，我应该早就在更灿烂的地方做了更多了不起的事情了。）

3. 🟡openai云端给出标记后，会替换掉用户之前记录的标记，并根据标记结果进行反映，施加不同程度的降智处理。

1. 基本上技术派，走的是这一环。什么对话ID，标记，什么注入292.什么听不懂的，按照我的硬理解，大体应该都是这一环。我对于完全听不懂的技术不发表意见。（如果不是，不要讲给我，我好累。技术派搞技术，我只搞抽象）

2. 我们结论先行中提到过“抹除标记+打上干净标记”就是这里。同时上文的图片支持这点。不再赘述。

3. 这里看起来是可行的，对吧？至少原理上。但实际上并没有被大力推广。我们在上文4.2提到了它的标记替换周期250s。密集的替换，使得持续伪装的成本高昂。

1. 我谈谈我仅有的理解：干净标记似乎并不昂贵，很易得。但，持续性的，大量的，干净标记，会随着对话持续越来越贵。整体让该策略不可行。（尽力了）

4. 希望技术派，无论你们是出于什么目的搞的技术，虽然我也听不懂。但是，你们这里的希望是最多的。

5. 至于普通网友，我们旁观，我们等待。

4. 🟢施加降智行为后，不同用户产生不同的降智效果。

1. 关于这一机制，参见上文在3.4中提到的大胆推测。这里大体是根据标记给出一个统一的降智程度导致原有不同智商的模型呈现的降智效果差异。

2. 但这仅仅是推测。而且，更重要的是，我们对这点知道与否，几乎都不会影响局面。

3. 因为探测到标记→觉得施加惩罚P，给你换模型→拿到笨蛋答案→发送给你。整个链条几乎完全在云端发生。

4. 这一环基本只能接受。我们对此能做的大致是：

1. 尽可能敏感的探测到，抓到

2. 别让笨蛋答案污染我们自己珍贵的项目成果

1. 有一个开源软件脚model trace ,通过指纹探测降智，我们在结论先行的检测方法里提过，原理可靠，但结果单薄。我个人不再采用它的结论了。但它

有一个设计非常棒！

1. 用户一边用，它一边就进行自动检测，非常省心
 2. 最重要，如果它抓到指纹不一致（刻意降智），会主动通知通知用户，并立刻发指令叫停智能体。
2. 产生大脑内统计，改变我们之后对此软件的信赖程度。优化长期工具策略的演化。

3. 简单总结下：▲

1. 用户使用产生痕迹→收集变量：根据自己的理解和能力能有多少做多少
2. 收集变量→计算并得出标记：不可知，非常昂贵，和普通用户无关
3. 计算并得出标记→施加降智行为：技术派最可能攻克希望之环
4. 施加降智行为→产生降智效果：纯云端不可介入不可知，可增加检测和策略改进

5.2 英文倾向测试展现出有效结果的全程信息披露（不排除是专门针对简体中，繁体未测试，理论可行）▲▲

1. ● 结论先行：

1. 带有连续性的英文沟通倾向（至少连续英文沟通多次），尤其是再同一对话内连续追问多次，是明确有效的降智改善措施。← 不是单纯地问一句英文
2. 加UI的英文设置效果更明确。← 和英文沟通一起测试的，结论不敢单独拿走
3. 仓库名，项目名建议也保持英文，中文可疑！
4. 改善效果可持续存在，但不确定具体多长。
5. 重点在于，它不是让用户甲乙，从中文转英文后，恢复到同一效果，而是在两人原有的降智表现上，改善。
 1. 改善的含义是：增多可用模型及思考等级：按照现象描述，就是让你能答对内部知识测试题的模型和思考等级变多了。我们同样以上文提及的ABC模型简化举例说明：
 1. 比如你原来只有B3C23能答对题目。使用了之后，你会发现类似的，A3B23C123都答对题目了
 2. 比如你原来只有C3能答对题目。使用了之后，你会发现类似的，B3C23能答对题目了。
 3. 两人即便英文文化相同，最终效果不一样，因为两人基线不同。
 2. 改善的原理：如果从上文的3.4提到的大胆变量→标识机制来看，则可以这样解释：即连续的英文使用倾向明确减少了那个同一的降智程度（分数），从而导致原有的降智效果得到改善。

2. 发现线索→实验→推广验证→结论的过程

1. 🙏 郑重感谢“头像是一只可爱小老鼠”的网友（真是头像，不是账号）😊提供的英文线索，原文是：我是（在进行中文沟通的过程中）发英文的时候顺便让它给我改了一下英文的句子，不知道多了一个改句子的任务会不会让风控变松。还有就是，我刚刚试了一下，风控的时候开个分叉也会好很多。
2. 写稿的时候追问了下，对方表示需要多聊几句英文（才会效果好），这里中度可靠，毕竟我们沟通中我反复提到这个结论可能影响对方记忆里的感知
3. OK，信息量很大，很新。但原文依然是小小一句。我当时有留意，但没当回事
4. 之后群里有其他网友轻描淡写一句，用英文会好。
5. 这两个信息就啪的一下连起来了。
6. 我开始实验。依然是用同一套测试题。但当然，个体无法真正单一对照，混杂因素下文再说。具体实验过程我下文单写一节。
7. 之后拿到结论后，我很兴奋跟“小老鼠”分享了这点，我们俩都很开心。
8. 🟢我把这个结论发到群里，让大家帮忙测试，实际参与的可能也就五六个人，基本上都按照进行基线的中文效果测试 + 改英文规则后再测试的方式，**明确收到了大概3-4份的改善信息**（当时在群里测试的时候，没有负信号）。只不过每个人改善程度不同，最终可用模型也不一样。
9. 我匆匆跟“小老鼠”分享了这些，掩不住内心的喜悦，在小红书上发了一篇新帖子，还特意把封面设成绿色，寓意“畅通无阻”！

3. 后续反馈没有太多好消息，但也没有几乎没有坏消息。

1. 帖子浏览量大概2000+，讨论大概100，私信十几个，几十个？之后帖子被天杀的官方给藏匿掉了。无通知，无痕迹，账号检测一切正常。这里开放的窗口大概也就是2天。我还零星地在群里发布了这个消息，可能累积受到的相关互动可能也在20个以下。有效互动就更少了。
2. 🟢🟡结果并没有增多我太多的信心，但也没降低。我的意思是。主动用完，主动反馈说“确实改善了，真棒呀！”的用户小于1-2个，还想不起来具体的个体，至少感觉。但是，没有人报告无效！
 1. 测试成本高一些：毕竟这里如果想看到“改善”需要英文改动前后进行同一份测试题的测试，需要至少两次。我会认为大部分网友一般会直接采信帖子的结论，直接设置，而不是进入怀疑-科研-讨论层面。
 2. 英文的门槛，实际上可能直接打消一部分用户参与使用的意愿
3. 🟡必须要提及：
 1. 群里有1个用户明确报告无效，但是，可能我个人有偏见，不知道是没有沟通好，还是对方心情差。也不排除这种方法稳定性差。
 2. 有一个用户是进行了UI英文设定（细节英文不表，比如项目名之类的）后先开了多个独立窗口尝试发现并没有改善。我脑海里似乎没有下文了。就记得自己当时内心的推

断：“那也许同意窗口连续追问权重更高”。不确定这个网友和上面说没效果的是不是一个网友，我有点疲惫，记忆也有些丢失。

4. ● 我个人的实验过程（codex内）：

1. 我个人plus未更新codex，没有6-luna,6-sol，所以这两个没测。主要用了5.6sol,6-as进行的测试

2. 基线表现：

1. 理论上我应该即刻进行一次基于中文提示词的对话确定真正的基线，但是当时我好像没这样。原因忘记了。
2. 我反正之前知道自己只有6-as-max可用。但当时确实没有再测试，或者我测了？但是忘了？不记得了，我的实验进程没记录这点。

3. 单一窗口连续英文追问：

1. 设定：新窗口，英文提示词，UI中文，没选仓库，自动生成英文的项目名，
2. 行为：同一个窗口，从6-as-low一路问到6-as-max
3. 结果：只有max回答出了对应题目
4. 状态更新：
 1. 此时我已经在同一窗口连续英文追问了多次，但我的UI还是中文的。
 2. 哦不过，中间的追问似乎都是英文的。我好像就是。大概是同一份提示词，不断地发，让它回答，反正小思考没回答出来，不影响后面自己回答。

4. 多个新窗口英文提问，不追问：

1. 设定：新窗口，英文提示词，没选仓库，自动生成英文的项目名，UI中文，
2. 行为：单独问，6-as-max一路下降到6-as-low，每个新窗口发送英文提示词。
3. 结果：在逐一发送的过程中，发现，6-as-max/xhigh/high/medium都能回答正确，low不行
4. 状态更新：
 1. 我现在已经同一个窗口连续英文追问多次，并且不同窗口英文沟通多次。
 2. 虽然我没有跟踪时间，但是这一套下来，必然跨国250s边界妥妥的。

5. 我改了UI语言为英语

1. 设定：现在是纯全英环境了，至少这个对话，我其他原始对话老样子。自动生成英文的项目名，没选仓库。
2. 行为：逐个新窗口提问，从6-as-low往下提问
3. 结果：发现6-as-low，5.6-sol-max，5.6-sol-xhigh均能答对自己i对应的题目，但是再往下就不行了。

5. 细节剖析与初步推断：

1. 感觉好累，可以不写吗？大家想听啥？

2. 感觉要分析的因素太多，从何落笔？好想先睡一觉。（审核也好累，心脏快受不了了😓都是低质量审核）
3. ●首先我认为，英文的使用倾向，有效改善是明确的，也呈现了跨250s周期的效果保持。结合后续群里专门的3-4人的反馈，我对这点是比较明确的。
4. ●但是结论上需要稍微谨慎讲话：
 1. 勉强能说，不改动UI语言也有改善效果。不过我让网友测试的时候，都是直接让大家把UI改成英文的。能改就改成一致的。如果英文真的是一个明确因素，那么，UI只会对效果更好。（不行了太累了，去躺一会，心脏好累，不过我快结尾了，后面不算太难，推测嘛大大咧咧来就行，不用像实验这么严谨）
 2. 所以结果的"明确改善"必须锚定在**UI英文+英文痕迹（对话名和项目名）同一窗口连续英文追问+多窗口多次英文提问=四个绑定因素**下展开的。
 1. ●其中，**UI英文，即便不设定，应该也有改善效果，但加上更明显**
 2. ●**英文痕迹倾向于必须也是英文的**：证据来自于我写稿前的临时测试，但是混合了模型灰度（5.6答出了6的题目）的效果，我简单写下不展开了，太累了不知道今天是否写得完。
 1. 我本身已经UI英文，新窗口，英文对话名，项目英文名，英语提示词，直接6-sol-xhigh.毕竟自从上次英文测试后，我没动过codex。中间答出了6的题目，我不开心，我后面又准备了一些题目，表现为，答出来一两次，没答出来一两次，毕竟我这里用了不同的题目测的。我心理期待6的灰度效果快点走。但整体效果可以理解为可能"勉强算它答对把"。至少交替混杂了答对6，答不出来，答对了5.6，毕竟在多个不同的测试题上。
 2. 我立即新窗口6-sol-max测，预期，既然6-sol-xhigh勉强还可以，max应该是明确可以了吧，结果测试一圈发现不行。这时候心里开始打鼓（咚咚咚！不要啊，求你啦。）然后不得已再开新窗口测回xhigh，这时候发现刚刚的max自动声称的题目变成了中文，我明明是提问的英文，而且UI一直是英文的，不明白中文如何产生，但显然，max只答出了5.5。此刻我就严重怀疑中文对话名的污染了。
 3. 新窗口xhigh，我印象中好像也没有答对，我不死心，鼓励它，然后它开始猜，然后我检查，然后我吐血。猜居然都猜对了一半。
 4. 开始感到头皮发紧，意识到需要更新对提示词的可靠性认识，修正之前的结论置信度，结论边界，调整唯一有效的英文测试结论的置信度。头皮发紧，不愿意面对。这一部分的经验参见上文相应章节。
 5. 尽管发生了这些，但这里的混淆因素也很多，比如，遇到了似乎是灰度6的行为，刚刚碰到过对话名被不明原因生成中文，后续的测试结果可能受到相关影响。这里不再细究。维持主结论不变，修正边界，补充细节，诚实披露。
 3. ●同一窗口连续英文追问是高置信度有效的，多窗口似乎有更好，没有好像也行。

1. 🟢”来自可爱小老鼠“最初的线索反馈，它并没有进行多个独立窗口的英文提问。
2. 🔴上文5.2.3.3提及的网友经过多个窗口独立追问，但似乎无效。混淆因素很多，而且其他信息不足

5. 🟡可能仅仅是简中被视为高分析因素，而非中文：

1. 这一点没有经过测试
2. 但这对大部分用户来讲，英文门槛明显，繁体中文也要好过英文，值得一试
3. 原理上说得通
4. 我们在上文的影响表示的变量因素里提及过，国外的华人也有被降智的明确报道。这可以成为支持简中的弱证据之一。

6. 其他结论边界：

1. 累了，怎么一直在报告边界。老样子，数据少，测试题够呛，测试不严谨，测试次数太少，测试时间有些短。
2. 混淆因素复杂：
 1. 比较显著的混淆因素是：新分支新对话。我们在上文谈到该因素有可能是影响标识的变量之一。“小老鼠”的报告恰恰就是在连续中文对话中，临时分支出去，进行连续英文对话而产生的。但我的个人测试显示即便在同一个会话窗口连续的英文对话也增多了可用模型。
 2. 包括我写稿前的临时测试混入了一些灰度5.6到6，也可能印象我临时测试的判断。
3. 后续的反馈并不积极，也包括我自己心态放松了，所以，没有主动跟进。就这样吧。差不多了。但是不知道是不是自己状态不好的原因，总感觉这里有什么忘了写。（想起来了🤔已经补上去了。我就说我感觉无敌！不过心脏不舒服，今天不知道能不能写完，太累了）

7. 进一步的推论

1. 该现象似乎说明一些针对性信号。（参见下文10.3，10.4关于目的的分析）
 1. 首先，我发现这点是时候，当然不开心。我的第一反应是，哦吼，gpt开始学claude了是吧。想干嘛？
 2. 🟡又想了下，有一个角度可能更合理。我们还是从降智的目的出发（具体目的的介绍参见下文）”防范反代，防范蒸馏“的角度来看。
 1. 🟢蒸馏毫无疑问，我们国家的蒸馏是大体量的
 2. 🟡好像最近半个月还出过那个国产模型把你的答案路由到gpt和claude并回答你的新闻，新闻提及，目的是为了获取思维链。该新闻存在争议。
 3. 🔴号商，虽然觉得外国也有中转站和号商，但我感觉我们的体谅也够大，够明确，不知道外国人会不会直接从我们国家买。但这一点纯猜测，无任何数据。
 3. 🟢看到这里，你想必也明白了。这些目的似乎都可以指向一项具有辨识度的特征——中文，尤其是简体中文。

4. ●当然，这毕竟是推测，但，如果我是openai的老板。我负责这部分的技术防范，这个因素不算进去，我恐怕是要被辞退了。
 2. 但它是不是要走claude那一套，我不清楚。我只觉得我受到了伤害。被针对性受到了伤害。也许这是：
 1. ●严厉打击反代和号商措施升级产生的不可避免的连带伤害
 2. ●战略上，要抛弃部分特定用户。
 3. 不管openai内心是什么，我都觉得相互很累了。感觉早晚要分手。往好处想，也许，这是一个练习英语的好机会。上天送给我的练习英语的好机会。(😓有失必有得吗？可是这也太不公平了！)
-

5.3 sub2api是什么？有效吗？

1. 我没有使用过，所以，知道的非常有限，我给一些非常简单的介绍。
2. ●大体就是这个工具能把帮你把网页版的聊天转成一个api接口，方便你对接到你的其他专门聊天软件中。好像也能把一个大的比如20x订阅等级的codex里的额度分发成几个独立的小额度，然后供多人使用。——不知道这俩是不是俩软件，我姑且都当作sub2api的功能来解释。
3. ●这并不是专门为gpt打造的工具，这是为所有大模型使用场景打造的工具。这意味着，你可以把它用在chatgpt上，用在claude上，用在gemini上，用在deepseek上。
 1. 网页版聊天一般免费，而api则要付费，该软件就帮助剩下了一部分调用api的费用（毕竟你的真实对话实际上是在免费的网页版内发生的，只不过你的使用体验是在自己的特定软件内。）
 2. 后面提到的大账号分发小账号/api这个就更有利了。中转站可能用的很多。之所以这样成立是因为20x的费用是plus的10倍，但额度却是后者的20倍。因此，假设我有一个20x订阅账号，只花费200美元，我可以通过工具把他拆分成20个plus的额度，分别卖出去，每个如果将近20美元（实际上需要便宜一些卖），我就会累积收款逼近400美元。大体这样吧。总之这里确有套利空间。
4. ●这好用吗？——在之前的规则下，应该是很好用，在现在的规则下，不明朗。
 1. 之前绝对好用，一方面制度宽松，另一方面，开源软件+（诸多好处）使用的人应该不少。
 1. 从仅关注过的2群里来看，感觉比例至少20%，毕竟我是临时加的两个专门的就讨论codex降智的群，这些人的技术含量搞一些也很合理。小红书上，由于用户偏差，在和我互动的人群中，知道的人并不多，似乎不超过0.5成，也非常合理。虽然听起来不多，但从千千万万的工具角度，这已经非常可观了。
 2. 大家在相互的降智沟通中，尤其是晒路由的过程中，也总是非常频繁地提到这个软件。我个人认为在长期使用各种大模型产品中（不包含只会使用豆包的那种群

体，它们的技术需求并不强烈）至少一半以上的人多少应该听过。区别可能是像我一样，打算或不打算用。

2. ● **现在还能用吗？**，能用，但未必能改善降智，稳定改善就更可疑了。同时带来进一步的降智风险。

1. 绝对还能用，工具的基本原理没变。整个降智的讨论中，网页也频繁晒出sub2api的路由截图。这表明现在现在的背景下，依然有不少人大量使用且信赖。
2. 但能用是只以它原来的目的而言，能用。我们要问，openai，是在一旁眼睁睁看着吗？（具体参见下文10.3对于反代号商的打击。）简单来说，openai对此完全清楚，并明确表达了反对意见，在处理措施商程度不同，机制不透明。可能包括不限于“从毫无动作到封号”。

1. **如果它没抓你，当然没动作。**

2. ● **有一些信号可能与此是相关的**（如反代/号商/多人共享），**动作跨度大**。但我的信息零零散散，由于没有太留意过反代，所以没有确认过信息。

1. ● **capacity** 的容量警告，（capacity和ip的关系参见上文4.5.2.2.2）

1. 我明确没有留意到谁说过是自己反代/共享导致，（好像印象中有1-2个网友大致有提到），但严重怀疑似乎是合理的。
2. 所谓容量不足，未必是真的不足，看起来更像是一种openai探测到可疑活动后的权限限制。
 1. 支持的理由是，（不少于2位）明确有网友提到，自己尝试了多有的模型，全部报告同样的容量限制。而同一时间，我很肯定，更大量的人正在使用，且官网并没有出现让所有人奔走相告的status异常。这看起来非常“量身打造”。
 2. 与此同时，这些在X上抱怨自己遭遇了capacity的警告的人，很多是非常愤怒的，同时，它们并没有顺带提及一个“告知邮件”，类似于“因为XX，我们准备把你的账号XXX”。我当然不是说它们有披露的义务，但有原因的遭遇，和没有原因的遭遇。会影响公开的表达。它们表现得就好像自己是无辜地，遭遇到了莫名其妙的特殊对待。而且官方对此，几乎没有明确的解释和正面回应。这种capacity的哀嚎持续了相当一段时间，感觉至少一个星期。之后，可能是部分缓解，可能是降智问题变得更重了导致大家抱怨的重心偏移（不排除我的视觉偏差）扯得好远，我只是想表明，这更不太像是师出有名的措施。且符合如今这种暗戳戳告你的风格。

2. ● **收到cyber abuse，网络滥用警告邮件。**

1. 这里同样没经验，纯推断。
2. 有一个网友公开表示自己不介意（说的啥忘了，反正就算乱搞），然后收到了大概3封警告邮件，还传授经验给网友说，然后后面就封帐号

了。这很合理。收到持续的网络滥用警告，严重可能导致封号。但这样侧面说明，也许一两次的这种警告，账号则是相对安全的。

3. 但是我们上文提及的sub2api所代表的各种非常规活动是否必然只对应cyber abuse，还有其他警告类型吗？那我就知道了。但cyber abuse警告与此密切相关是用脚趾头想也对的。哦，当然，如果真的很严重，也完全可能导致无中间过程的直接封号，这也似乎不需要解释。

3. ●能用不代表没账号风险

1. 这是明确被官方点名的（参见下文10.3.3对于反代和号上的打击）
2. 风险感知参见刚刚上文提及的警告邮件和封号。但这里没有更多进一步的数据了，不知道强度如何，不知道范围如何。如果到官方的敏感性如何。
3. 同时，请留意，你尝试解决问题A所尝试的新工具B，尽可能可能解决A问题，但也能同时引入C问题
4. 除了我没提到账号封停警告的风险外，我们在下文来谈谈“降智风险”。

4. ●改善降智绝对不是！但可能可以对抗降智，局势不明

1. 它本身绝对是风险因素。可以肯定它的特征肯定能抓的全抓，里面的高度具有辨识性的信号必然是高权重。但进一步的变量是谁，谁更重要机制不明，
2. 理论上，不用它的风险要比用它的风险低。但用过之后账号是否会产生持久标记——这点没有信息，但，似乎倾向于不会。或者说。至少好像其他的变量更能快速影响脏标记的产生和擦除。

3. 如何对抗降智？

1. 在网友的热烈需求下（我完全相信外国网友一样有兴趣，尽管中国人更多）sub2api的开发者，也在升级自己的开源项目 —— 以对抗openai的防护升级。
2. 同时还有其他更多网友自动加入到开发和维护的队列中。我目前已知已经有网友开发到了sub4api，听起来像是第四代，并明确表示sub4api支持自动打票（行业黑话，我猜大概就是我们上文在标识和方法里提到的自动抹除脏标记，打上一个干净标记）
3. 但如果这里的打票就是我理解的那样，参见上文5.1.3里提到的攻克链路介绍，我维持原有看法，这并不是那么容易。
 1. 有一层依据是来自于尽管好像sub4api支持自动打票，如果它足够好，传播学的涟漪应该把它送到我能触及了网络了把。但群里好像没有人喜大普奔地报告这一点。（我当然也只有两只小眼睛，有限的经历，和窄窄的信息源）同时，我们在上文提到，sub2api可以算明星项目，知道的人不少，虽然不一定有很多人知道由其他网友继发开发的sub4api，（顺便说下，大概昨天，sub2api的作者也更新了自己的项目）但这些用过的人，大部分肯定盯着呢。科技关注具有粘性，急切，跃跃欲试，自发传播的特点。我从对打票原理的猜测 + 它传播速度的感知推断，可能并没有那么好用。

2. 同时，咱也没用过。更何况，在这个节骨眼上，出于风险防范，可能真正尝试的人，也少。甚至发现自己降智后，如果原本在用sub2api的用户，肯定首选的变量调整就是停下使用它，然后起到自己的模型效果变好。
4. 简单来说，官方和sub2api的同类工具在相互博弈，共同促进对方升级。目前有类似于sub2api升级的积极信号。但效果似乎不太乐观 + 啃食螃蟹人少，最终对抗状态不明。我个人两边都积极预期。积极预期openai官方的防控手段只高不低，也积极预期同类的产品会迭代带来惊喜。（甚至从excel入口反代codex（参见结论先行中5.5）来避免降智这种刁钻的角度都被想到令人惊叹。）这就属于中心算法和分布式对抗的结构了。

5. 总结：

1. 🟡明确的风险信号，但程度不明，不会太低，但也不会因为一次行为打永久标记。
2. 🟡现在使用它的人依然不在少数，但要留意每个人本来的风险承受本来就不同。
3. 🟢后期该产品也肯定会升级。有效性未知。也许你不需要特别关注，但请相信，如果某个工具足够好用，它就一定能传播到你面前，如果它没那么好用，也自然省去了你辨别的烦恼。

6. 降低额度

1. 🟢很早就开始降低额度了，从5.6还是领头羊的时候，
 1. 说起来了，我记得那时候，模型智商就处于波动状态。
 2. 依据来源是我关注了一个测试模型智商的网站“雷达社区”，是由众多网友花费自己真金白银的额度共同参与，相当于谁有空谁跑一组题目。这些题目都是那种经典题目。模型训练的经典题目。题目量很大，模型又贵，各个模型的测试预算并不均衡。所以，测试结果虽然说是实施滚动10分钟刷新，但实际上，由于模型太多+ 题目太多+参与用户有限+用户回挑自己偏好的模型进行测试 = 结果对比并不太可靠。但这依然是所有不可靠中的比较可靠的数据啦。
 3. 🟢早些时候，我确实在这个网站观察到降智和降额同时发生。
 1. 算力不足的时候尤其明显
 2. 降额很明确，不用说。也容易测。
 3. 降智要好好说说：
 1. 如上文所言，可能本身就并不可靠，测试题目虽然质量很高，但测试过程将会产生波动性极大的结果。
 2. 而且那时候就算有降智，模型可用性应该还可以吧。只是可惜那时候没有测试过，但是大家基本上都默认简单忍受，日子照过，现在虽然智商低，明天就会智商高。生活总归能继续。

3. 那种降智，应该和我们如今谈及的降智，不算一码事。但保不齐就是从这种降智演变而来的。可能这里提及的这些早期的降智表现背后的降智规则，恰好能对应上我们上文提及的“根据标记产生一个降智程度X”，里的“X”。也就是，以原有的降智措施，配合一套精密的降智逻辑，并调大点击程度（疯老头科学家在地下室捣鼓阴暗实验的大笑形象突然蹦出屏幕。走开走开快走开！）

4. 但是，我们跑的太远了，我陷入了一些轻度的被害妄想。我生了一些病。

2. 然后开始慢慢地，降额一致就成了默认情况，鲜有好转，几乎总是降额。

1. 这一点似乎天下平等，国外网友好像也是这样。

2. 依据来自于x上大家的抱怨。

3. 我本来想，降额就降吧，咱就是一个小小的plus，降额是咱的命，不要给我降智就行了，日子还能过下去。

4. 然后呢？然后呢？！后来的事情大家都知道了。我月供交了一次又一次，不仅现在陪我的时间减少了，后来居然都开始撒谎啦！偷偷给我玩当面一套背后一套还死不承认。我的心伤透了，生活一地鸡毛。

5. 我现在写稿子的时候还感到眉头紧皱，觉得无辜又困顿，疲惫又无奈。关于美好未来的生活的憧憬，我很明确它碎掉了一部分，再也回不去了。怀疑的种子一旦种下，就会生根发芽，发展壮大。可是我在心底也很清楚，如果将来有一天，它再度熠熠生辉，我可能又会投怀送抱。好想未来的希望碎了，未来的我提前脏了。

6. 最后，我得说这样一句话，朋友们，金玉良言，良言金玉：不要妄图他人会因为你而改变。降额这种事，比降智还令人绝望。如果可以，只要日子回到以前那样，我就会既往不咎，踏踏实实过日子。我说的是真心话。

7. 申诉邮件

1. 没有太多可说的，结论先行说的很明确，基本上是敷衍和打哈哈。

2. 今天受到的网友反馈中，有一封邮件回应的内容对应了上文提及的【picture5】。只是更精致：（简化）“即便你付钱订阅，仍可能临时受限，无法提供更多细节，系统回自动评估访问权限，一旦影响服务可用性的相关操作终止，权限即可恢复正常。”

3. 建议：有精力写，感到疲惫就算了。写的时候请教gpt。

4. 个人已知建议：

1. 写好标题

2. 请同一邮件连续追问，不要短期分散多封

3. 如果是机器人就明确主动要求转人工客服

4. 如果人工客服打哈哈，就明确要求技术跟进

5. 尽可能伪装成讨论技术，表示在进行技术反馈——尽管我试了这次没用

6. 尽量避免提及：我要投诉，我要超你们国家证据部门举报，我要（还有啥威胁来着），反正这种，会导致你的邮件会被视为法律风险过高，从而自动转入法律安全监督下的回复流程，导致获得真正的回复变慢，也减少了客服在灰色责任地带愿意主动出手帮助你的主观意愿。

1. 顺便提及下，在国内，就医时也是一样的逻辑。本来医生/医院和病人的沟通处于普通医疗沟通下，但如果病人率先表达出“我要投诉你，我要详细拍照”则可能会导致普通的医疗行为，自动划入院方的风险规避的监督框架之下，导致你原本的正常医疗服务被保守处理。
2. 这甚至算不上是一个医患沟通的尖锐话题，是博弈框架本身决定的。写申诉邮件是这样，就医也是这样。
3. 知道这点可以帮助你修正你打算采取的策略和预期会得到的效果。

8. 中转站此刻什么状态？

1. 啊，我真是越写越快啦，眼看就要写完了。加油！（审核到这里，好累，当时好天真啊，以为会很快写完。）
2. 这里我主要就是感觉啦，数据少。让我们开始胡说八道！

8.1 它们正在积极推进，尤其是从技术层面，但进展似乎没重大推进

1. 上文好像哪里已经提过了，参见5.1。参见4.5.4
2. 依据：

1.  当然，中转商以及蒸馏公司会有巨大技术优势 + 驱动力和资金投入为大家实现这一点。

1. 我自己看到+群友传递过一个“降智科研”的概念，中转商似乎明确在做。甚至自己收号的时候都声称自己是为了科研！
2. 接触中，有可能是蒸馏公司的人员也在跟进（即便我对该对象推测错误，该论述也单独成立）。该推断可能出于我的偏见。对方并没有透露真实身份，但表达出强烈的隐私需求和探讨意愿，以及白嫖倾向。对方表示不愿意付费购买我的时间，但要求我承担保密责任，同时积极向我传达技术细节交换的意愿。我们实际上没有达成任何有效沟通。（如果真的达成，这条信息不会存在）如果我的推测成立，这至少表明它们也看到了一些明确有趣的现象（不排除纯哈哈）。只是我怀疑，是否比这份稿子所提供的信息更重磅？够呛。

2.   市场交易信号，略偏积极，够呛：

1. 积极信号：（我们在下一节分析这个积极信号。）

1. 群里确实看到有明确的信号反馈说它们从中转站买到了可用的号（确实有两把刷子，这会在人群中传递积极的购买信号）

2. (参见结论先行的3.4) 收号和卖号人数大体持平, 卖号的人更多, 但基本上处于只要你想出手, 你就能找到人接手, 只不过, 价格大概率打骨折! 主要看号的属性, 明确降智的号和声称满血的号不是一个价码。具体没关注过, 只是稍微撇过几眼。
3. 有那种服务“帮你解决自己账号的降智”, 一个网友告知我它花了60元, 效果未跟进。这个定价至少还算合理范围内, 如果能解决大问题, 不算特别昂贵。

2. 消极信号:

1. ●听说, 仅仅听说中转站卖的账号/api倍率很高, 我没接触接触过倍率概念, 但基本是物品稀少则倍率高, 价贵; 物品丰盛则倍率低, 价贱。这里的进一步推断是, 肯定号还是多的, 但宣传能修的好能卖出售的号, 则肯定没那么多。应该有相当一部分中转商需要同步推出退货服务才行。

3. ●进展:

1. 到目前为止, 突破性进展, 几乎=0
2. 零星部分修复, 蛮多的。这里应该不难, 根据我们上文提到的4当中的多因素标记, 理论上只要搞干净几个能优化的变量, 带来一些效果提升是可预见的。如果配合下文提及的8.2.2.2, 则我个人认为者稍微改善不难实现。
3. 但在当前局面下, 真正困难的恐怕是, 如何保持住不降智和更大程度改善降智。
4. 它们有优势, 也可能搞懂了一些原理(参加上文各种证据)不代表, 这样做容易。但其他节点可能更困难。(它们目前能明确进攻的点可能处于参见上文5.1中的第三点。)
5. 后期进展预期不明。

8.2 当它们宣传能解决降智的时候, 实际发生的是什么?

1. ●这里需要顺便提及, 它们看起来似乎也真有些办法。但效果应该够呛。
2. ●我印象中明确拉着至少一个, 大概2-3个, 宣传自己从中转站拿到/被优化后满血账号的网友做过测试, 同一套测试题, 只是常见模型等级(比如6-as,6-sol)答出了对应题目, (参见3.1, 混乱局面中的普遍降智程度), 并没有超过我们的统计的效果边界。但是我能理解。并产生一些非常有趣的推断。
3. 这表明:
 1. 它们应该明确知道某些因素能改善模型表现, 但当然, 也没有主动披露的义务。
 2. 但改善程度似乎有限到, 不及统计结果的平均表现。原因可能很多:
 1. 20x账号: 我们提及过, 订阅等级可能是一个产生脏标记的风险因素。我统计的过程中并没有明确根据订阅等级分层, 则这个平均表现是不是因为我沟通的主要是plus的温和小用户而导致的表现相对好些呢? 毕竟我的统计结果里面至少一半以上的高质量反馈来自于小红书的评论和私信。其中用户大概有2层(太纯感觉了)似乎没有其他

主要信息渠道获取帮助。而我在群里那些人，显然它们已经处在信息的中心了。我完全相信后者中20x的比例要远高于前者。诶呀，这里推论推的太远了，这是有必要的吗？让我们写简单一些。

2. **降智更严重的账号，尤其是20x的用户，它们不缺钱，工作阻碍更严重，它们更可能寻求付费帮助。这意味着，这些账号本身就更棘手。**

1. 但直觉在这里相反。纯直觉。

2. 感觉从超级严重到有些严重，要比，有些严重到不太严重，更容易。好像是越往好的方向，越困难。而从超级严重改善的话，似乎只要上文提及到的几个关键因素搞赶紧一些，改善的可能性应该不算小。

3. **中转站大概率并不是有意隐藏秘诀**（尽管它们有驱动力这样做，反之它们中的某些技术人才也在各大论坛积极提供互动和技术支持，参见上文提及的图片），**事实上更像是，这些秘密无人晓得。除非你从今天这篇文档里，透过统计学的视角，跳出个体互动，又抽丝剥茧，才能触及这些推论。所以，这里的情况大概率是：用户真的想寻求付费帮助，服务售卖方大概率真的知道一些好技巧，尽管是有限的好技巧，但确实帮助用户改善了使用体验。它们在之前，之后也许做过简单的测试，但没有更多。双方都开心。用户获得了帮助，解决了问题。卖方获得了金钱和成就感。皆大欢喜。顺便提及，其实通过网友（参见结论先行中的3.5）的普遍情况统计，大概率只要恢复一两个高级模型，用户的满意度就会很高。**

9.openai官方什么状态

1. 它们知道这一切

2. 它们也知道我们知道其中一部分

3. 它们有意回避了这一切，

1. 一方面表现得毫不介意

2. 另一方面又刻意准备了统一的宽口径篮子装下一切抱怨和申诉，仿佛这些信息都不必要被处理：是的，付了钱也会有限制，细节不便透露，请自行阅读规则，有情况再联系。

4. 它们很忙：更新的生意，更贵的套餐。

5. 它们野心勃勃朝前：是的，你降智了。但是大家只会在意我们解开了哥特巴赫猜想。

• 我确实需要补充2点：

• 我有受到大概2位网友，感到急切和困惑：为什么openai官方不管呢？

• 还有至少3-4位网友真的在意申诉邮件，打算把自己辛辛苦苦两个小时搓出来的盐巴块投入大海之中。

• 当妍珍急切且愤恨地质问“那为什么不回消息？”的时候，河道英几乎头也没动，只是冷峻地翻了个白眼，继而说道，“我回了，回了沉默。”

- 这可能表明，降智作为一种明确的策略，且打算长期（暂时较长时间）推行。
 - 但我们上文也提到，这个规则本身具有动态属性，上次新模型发布就有变动，只不过是变得更鸡贼了。下次开发者大会大概率也会有规则更新，我怀疑可能还是鸡贼更新。
 - 10.2.3.3.4，它们没有必要为短期过渡投入如此个性化精致化的昂贵成本，所以这可能是长期的。
 - 我确实不太了解大公司的营销或者战略部署逻辑，感觉一涉及到特别政治的事情，我就开始变得像怨妇。想要尖酸刻薄地狠狠挖苦一番。我不会啊。真不会啊，没人教啊。
-

10. 降智的原因的综合推断

- 如结论先行中已经表示的几点，我们逐个来聊聊：
 - 算力不足
 - 营销需求
 - 打击反代号商
 - 防范蒸馏
 - 战略变化。
-

10.1 算力不足

- 非常明确的算力不足，这一点至少是从??忘记了具体节点，但随着openai公司的疯狂营销，哦，大概是从7-8月开始，codex订阅用户飙升，模型需求扩大，市场买入信号强烈，一度搞停了20x的订阅。
- 我记得当时大家相互告知20x停止订阅时，我也在心里翻了个白眼，我表示：我才不相信大家说它们会因为算力不足停止订阅，有钱干嘛不赚？反正都已经降低额度了，（那时候降智的事情还不明显），不如随便再将降，钱还可以收，服务又能提供。
- 结果后来果然停止了20x的订阅。我认为这里，算力真不足占主因，营销占次因。反正，真诚也是套路之一。
- 后面算力应该是多多少少有缓解，毕竟恢复了20x的订阅，并在0-27日网上还有新闻说openai即将退出50x的订阅。这里只可能有三个算力来源。
 - 外部注入：我完全没跟相关的新闻，一点信息也不知道。但我如果是openai的老板，我当然！20x的订阅都停了，我能不急吗？势头正好，而我野心勃勃，当然要买入更多服务器。越多越好。
 - 内部原有计算效率优化：这一点对于搞大模型的公司并不陌生。实际上，同样的机器，要达到一样的计算结果，好的模型架构和基建配置，通信设置等，可以极大地提高计算效率，节省空间。

1. **这里的改进空间可不是一点点。**大公司肯定有专门部门会专门帮忙做效率优化。甚至有些实验室专门就搞AI infra（基础设施），不玩追赶顶级模型那一套，而是押注在现有设施和效果，但更高计算效率，更低成本的方向。
 2. 虽然这也并不容易，但，openai是顶级科技公司，所以，理论上，它自身的计算效率优化应该已经长期处于最优状态了。**这使得它在自己原有基础商提高计算效率的空间已经非常有限。**
 3. **更何况它们不断发布新模型，这会给原有的效率优化引入更多混乱，让计算效率的进一步提升变得不那么容易。**
3. ●最后，就是。哎，怎么写。**改变承诺。**
1. 如果我们答应过收钱后，明天给出10颗糖，但以融化成一颗大棒棒糖的形式交付。
 2. 等你明天收货的时候，你说，欸？怎么好像变小了嘛？这个？这个.....
 3. 对方拿手指头戳着屏幕：“看这里，看数字，里头有十颗糖呢，慢慢吃吧”
 4. 你叭唧了两下嘴立刻就吃完了，你感到一整强烈的碳水戒断的暴躁感，并严重怀疑是不是自己吃的太猛导致的。
 5. 这时候，它又出现了。变魔法一样地掏出另一根棒棒糖，你盯着直流口水。
 6. 它在面前晃呀晃呀，就是不说啥时候给。
 7. 等到它晃够了，它才会在一阵熟悉的欢呼声中把棒棒糖递过来，递给你的时候，还不忘用手指头戳戳你的屏幕”啊，这里，看这里，这个额度，100%了。我送的“
 8. 啊，是棒棒糖呀，甜甜的呀。我们都爱。太棒了！
 9. 我目睹了这一切，因为我就在其中，我就是那个买了棒棒糖的人。
 10. 但是，我们还有哪一部分的故事没有讲对吗？
 11. 我不知道了，我只知道，我接受过九年义务教育，我学过物理，物理说过，能量守恒，没有魔法。
-

10.2 营销需求

1. ●它们有强烈的营销需求的底层逻辑支持 + 驱动力：
 1. 首先，它们所处的商业玩法就决定了这种顶尖的科技公司要想要一直保持领先地位，营销非常非常重要，不能说基于产品本身，但至少地位相当。你的模型/产品，都不一定需要是最好的，你只需要让更多人，相信，你是最适合它们的就行了。—— 对所有公司都成立。
 2. 新模型不断发布，竞争公司不断挤占市场，它们已经绑定了诸多上下游行业的生死，需要向上交代董事会，需要向下交代市场用户政府，巴拉巴拉巴拉.....

2. ● **它们也确实这也表现**，此处是各种新闻碎片和营销的帖子碎片，如果你没有关注过，只需要知道它们表现得就像它们应该表现的那样积极营销就可以了。

1. Tibo的帖子，官方的帖子。
2. 各种莫名其妙的新闻发布时间设定
3. 各种刻意的，跟竞争对手的发布会打架 —— “我气死你！”“嘿嘿！我没被气死！现在气死你！”
4. 甚至，很多你都不知道是不是瓮中捉鳖的营销套路。不敢猜。此次需要grok的阴谋论音色代我发言。

3. ● **营销和降智有必然联系吗？—— 我的推断是巨大诱因之一，但可能不是主因**

1. **这里其实非常有趣**

1. 如果你跟过我**早期的帖子**，你会发现，我曾经专门写过一个小帖子表明自己发现了openai的秘密，并提到降智的主要原因可能不是大家自己的账号，而是营销需求导致的

1. 写了一些删掉了，长短短说：**当时，现象明确+体验符合+机制不明，目的不明**

2. **从目的倒推机制，我把目的理解为“算力不足+营销需求”**

1. 一方面是我们自己确实出于这种感受 + 我的初步统计感知也支持这是大规模现象 + 确实接触了很多openai高调营销的新闻，这使得我突然想起一个外国网友提供的推断。

2. 一个外国网友大体说“openai为了让新模型（6-as刚刚上线）效果看起来更好，降低了其他模型的表现”

2. **从目的倒推机制，从机制倒推现象这条链路基本合理：**

1. “算力不足”板上钉钉，那么模型都降智，但又要发新模型了，有营销需求，我们得让大家宣传我发的“新模型”非常棒！所以，新模型的智商又得保住。顺便让其他笨蛋模型笨蛋思考的表现衬一衬，真是一举多得！

2. 如果这种机制成立，则现象非常吻合：大模型大思考能答对题目，小模型小思考不行。

3. **但当然，这条链路并不严丝合缝，而且从目的出发推现象也太远了。**细想想就能意识到这种说法解释力非常有限：

1. **首先算力不足+营销需求两大目的绝对成立**

2. **但它们是产生降智机制的主要原因吗？—— 这里的跨步本身就很大。**

3. 我们假设说法成立，假设降智就是为了这两种需求。那么你不得不进一步回答**这些问题：**

1. 那为什么好像模型间模型内的**分界线处于波动中**呢？

2. **个体差异有必要这么大？**像以前一样统一降低额度和对模型智商进行波动不是就好了？（说实话也不知道以前的额度降低和模型智商波动是不是统一的还是有个体差异的，但当时只是大家都遮以认为）

3. 如果是营销需求，那么只把6-as留下来，其他模型统统降智不就得了？为什么有时候5.6-sol也能答对问题。这似乎是一个强烈的反驳证据。
 4. 而且，这个降智机制看起来非常认真，因为它“太个性化！”“太量身打造了！！”“甚至愿意为了新模型升级内部机制！”“哇哦~”。这意味着，这套机制可能存在较长时间。谁会对只准备实施半个月的一个临时操作投入如此多的精密调整成本，并甘愿承受由此带来的长期信誉和利益受损呢？openai只是很忙而已，不是忙昏了头。
 5. 这是一条稍远的反驳证据：6-as都发布好久了，少说半个月往上了，即便是新出的模型6-luna,6-sol虽然还不到一个星期，但也只是在原有的6-as基础上表现力往下的模型，尽管带来了一些成本优势，但是，为了这仨新模型搞营销从而降智其他模型会不会未免太久了？甚至有点久到不太符合营销里的“新鲜感+时效性”。而且openai似乎后期（来自X）似乎在高调营销月底的开发者大会。那这里呢？出于营销6的目的降智后，你就把车走往下一个目的地了？
4. 但话说回来，营销能不能在其中扮演一个影响现有模型效果的目的呢？
1. 我个人认为，营销需求很真切，但为了营销刻意降低其他模型的表现，则？好像有点过头。虽然大公司竞争激烈，但6-as的模型表现，应该是有目共睹的。在外网大家对它的额度消耗太快而抱怨的人数要远远多于抱怨它的表现很弱智的人数（完全出于个人两个眼睛的统计偏差）它们似乎没有必要在这里对6-as表现得信心不足。
 2. 营销增长带来算力需求增长，同时也会吸引来更多危险的猎食鲨鱼和汲汲丛丛的xx(生物知识匮乏，就是那种顺便捡漏占便宜的的小鱼)，这一目的本身就和其他目的无法分割。出于营销考虑，绝对在内，但由于营销需求进行降智，则有些远。
5. 所以，最终我认为上文3.4提到机制可能更合理。同时降智的目的可能更广泛更偏利益防护，参见，哦，参见本节。

10.3 ●对于反代号商和蒸馏公司的打击 —— 基本是长期公司政策，但强度当然可以调整

1. ● 对，当然。它们天然利益冲突。防范反代和号商也不是秘密。重点在于：以前好像还好嘛，最近这么猛吗？
2. ● 我只能说：合理的。战略上是长期合理的。几乎没有证据支持现在在减弱对反代和号商，以及蒸馏的打击。同时有些证据支持打击升级了。我们一起整理下：
 1. openai官方在X上明确表达了支持第三方api介入codex（欢迎合法途径），以及明确表达了反对反代的态度。甚至专门点名了一个在反代需求上功不可没的明星项目（sub2api）。实际的相关帖子应该比我要知道的更多，我仅仅关注的这些都是态度非常明确的。

2. **公司明确反对蒸馏。**虽然它们也肯定蒸馏别人，但是这个行业就是这样的。请不要问我的来路是否卑劣，你只要知道，如果我攀上顶峰，以往在罪过就会像雪花般飘散。
3. sub2api同类的反代分发工具+ 同类的检测降智工具也处在明确的升级中。openai当然知道这一点。不可能预期它们知道后却降低防护。**无论是反代，号商，还是蒸馏公司，也会大量用这种类似的工具。**（我的知识匮乏，它们实际上还会用其他更多）
3. **● 现有的数和机制确实击中了反代号商/蒸馏公司的一些独有特征：**（参见上文5.2.6的从方法出发的进一步推论）
 1. **影响标记的变量很多都会在反代或者号商上表现得比较独特**（参见上文4.4影响标记的变量）：并发数量，使用额度，ip变动，中文，还有很多我不懂的技术变量
 2. **目前看到的降智机制如果成立，则对其打击也很直接，甚至有些精准：**
 1. 按照第四节提到的多变量，滚动周期，隐匿性的降智机制（仅为推测），连续的降智光谱（仅为推测），等，那么，其实相当于：
 1. **”污染号商的产品“，导致它们出售困难，利益受损**（参见8.1.2）
 2. **”污染蒸馏的逻辑链和答案“，让他们无意中花费了巨额成本却无法出师。**
 2. 按照5.1的破解分析，**成本高昂，技术难度不低。**
 3. 我们也提到过该机制有**长期存在的倾向**（10.2.3.3.4），**且会动态变化和升级**（4.5.3）。这与防范反代号商和蒸馏的长期战略需求存在动力学一致性。
 4. 啊呀。哎呀呀呀。我如果是openai的领导，我开完董事会，听到这样的报告，我就会点点头，不辞退负责人了。
4. **● 完全封禁是不可能的，这是一种长期的生态现状，只是波动性强弱的问题**
 1. **这种情况会存在，且会长期，动态地存在。**
 2. **我们正在经历当前的阶段。我们还会经历未来的其他博弈形态。**
 3. **我们提到过，有需求的地方，就有人。需求不灭，供给就不会消失。**
 1. **市场上的反代号商与想要寻求更高性价比的用户，以及技术圈内相互的蒸馏和窃取，它们会一直存在。**
 2. **你会听到更多新的新闻，但都是旧的故事。**
 4. **这里能寻求到的最好的结果，也许就是，温和且稳定的局面，而非来回蹦高打架的的局面——我之所以这么说，是因为我很清楚我是nobody，就像上个世纪某块土地梗上戴了一顶破烂遮阳帽的农民一样，是那种最普通的小用户，它们的感受无足轻重。**

10.4 战略变化及综合判断

1. **● 这种”降智措施“似乎看起来已经成为了一种公司的内部战略部署。那么出发点是什么呢？**

1. 我在上文提过(5.2.7)提到过，如果说这是类似于claude那种具有针对性的战略变化，证据较弱。但不排除
 2. 更合理的方向依然是上文提到的10.1，10.3.即算力不足+防护需求。
 2. ●其他普通用户的利益看起来可能是该目的需求下的暂时牺牲品。
 1. 从理论而言，现实世界的所有权衡都会面临一个两难抉择”我们到底是更能接受冤枉一个好人？还是更能接受放过一个坏人？“我明白，你会大喊大叫，觉得这莫名其妙，不公平，”当然是一个好人都不要冤枉，一个坏人都不要放过！“是的，我跟你的愿望是一样的。但这在现实中不会发生。
 1. 如果要尽可能不冤枉规规矩矩的普通用户，就可能让竞争对手/利益扒手钻了空子。
 2. 如果要尽可能不放过一个钻空子的家伙，则普通用户的误伤率必然提高。
 2. 博弈的张力决定这种矛盾的存在，而如果你确实想要实现愿望，则成本是高昂的以至于公司根本不屑于从这里出发去想。
 3. 任何（科技）公司，都需要始终围绕公司的长远利益为核心的，寻求可控的风险和可承担的损失。普通的用户在这里，只是公司财务报表上的一个数字。
-

11. 整体结论 ▲▲▲

1. 先来一个粗糙的总结吧：
 1. 通过至少对长达半个多月的降智现象的观察，
 2. 我们发现，现有的检测手段非常有限，最可靠的依然是鹌鹑和内部知识
 3. 在这样脆弱的测试手段下我们发现了奇怪的降智现象：大模型和高思考的往往对内部知识回答准确，并非按照模型清晰划分。
 4. 大部分用户并未发觉这点，导致大家都以一种”降智/不降智“的理解角度相互进行交易，和经验借鉴。
 5. 且几乎所有人都处于短周期的动态波动中。”短周期波动“几乎可以解释网友们非常沮丧的大部分不安体验。
 6. 我们已经抓到一些明确证据来理解产生周期波动的标记。这里虽然是好的技术切入口，但其内部同样复杂。
 7. 因为影响变量众多，机制不明。这里建议在个人范围内能做多少做多少，不要强求。
 8. 尽管机制不明，我们还是尝试大胆推测，结论指向了根据标记信号动态波动的所有模型及所有思考程度统一降智一定程度的机制。但请注意！这仅仅是推测！不等同于事实。
 9. 目前尚没有可靠的一劳永逸的解决方法。但尽管艰难，我们还是摸索出一”连续性的英文使用倾向（特指非简体中文，也许繁体中文等同英文，但未测试）“这一有明显改善效果的独立因素。这里是同样的建议，根据文章提供的线索和自己的能力，能做多少，做多少，不要强求。

10. 同时，请留意任何新的方法和工具，都可能附带一定新的风险，切勿病急乱投医。
11. 就算不提降智的事情，降额也是明确的，请大家记住，送你的重置卡，本身就是你应当的！
12. 除了我们普通用户，其他团体，比如中转商，号商，蒸馏公司，所有人都在积极跟进和参与此次事件。尽管目前没有可靠方案流出，但如果有真正的方案，也大概率来自于它们。当然，还有一部分希望，来自于那些擅长技术，又乐于分享的了不起的人！
13. 至于openai官方，它们可能是出于三大需求”算力不足+打击中间商+防范蒸馏“而选择长期实施该降智战略，并主动承担了附带的普通用户损失，用以维护长期利益和其他未知目的。

2. 边界，边界，还是边界！粗糙的结论也配有边界：

1. 当我说的越多，就错的越多。但是如果我不说，我的损失就更多。生活是这样的啊。请大家抱着审慎的目光，贪婪地查看把。如果我哪里有很要命的错误，请记住，我提前承认它，但我可能没有精力和大家一起拨乱反正，探查更多真相了。祝愿大家踏着这条轻薄酥脆的黄金路，穿越凛凛寒冬，一路走到春天。
2. 这份真相只是所谓真相的暂时切片。我对你能耐心看到此处充满感激。但这些文字会很快过时。你会很快看到新的变化，或对旧状态的新的解读。请记住，这些旧的东西，尽管曾经很珍贵，也是可以被抛弃的，而且要大胆抛弃。如果新的证据来了，新的状态，方法，机制来了，请大胆地拥抱它们！
3. 我只是个体视角，社会经历和接触非常有限，我要承认，世界或者真相，远比我所能想象的更宽广，所以，虽然我把结论约束在了一个极其狭窄的框架内，但我要承认，我所不知道的，难以理解的，无法窥探的秘密要比我谈及的更多。这意味着，在有限认知内，我持悲观态度。在有限认识外，我无法不乐观。

12. 我，纯个人预期和应对措施

1. 纯个人，我个人对一个月内能明显改善持有悲观态度。但对长期改善持有乐观态度。
2. 我个人需求比较少，所以比较灵活。我个人打算临时多花钱过渡，下月订阅费扣除前再评估，并调整方案。至于调整成啥，我自己也不清楚。
3. 后期不再密切跟进相关信息，个人精力透支已经达到了失控的边界，需要防护。
4. 出于同样的理由，我后期不再积极回复各种信息，默认不再主动参与。这并非是由于你的信息不值得我回应，而是因为我无法保证以我有限的精力能给你同样好质量的回应。
5. 只有一种情况例外：如果我听到所有人都在传一个好消息的时候，我会跟着喊一嗓子，尝试告诉更多人（但不承诺这点）。

13. 同在的心理支持

嗯……我已经拖稿子拖太久了。以至于我感到不好意思看催稿消息。但是这一节依然非常重要！我终于能说一些让人感到轻松的内容了。

从何说起呢？

从我自己已经半个月工作停滞说起吗？还是从有位网友跟我留言她前天都哭了说起？有人发帖子骂自己是笨蛋不会用codex。有人把自己辛辛苦苦创立的项目丢给codex后被喂了一堆垃圾……

起初，我们都以为这是自己的责任。难过就好像是活该一样。

我的网怎么？

干嘛不遵守提示词？到底要怎么问啊！

天哪，是我用的太多了吗？

如果你能看到这篇稿子，说明，你至少现在明白发生了什么，明白我们站在哪里。但是有更多人，它们依然处在我们所经历过的糟糕感受里。

这非常重要。

真的非常重要。

如果你路过它们，请拍拍它们的肩膀；如果你觉得解释起来太复杂，请把这个篇稿子发给它们。没有人应该被刻意地被欺骗，被丢在一份根本不必要的痛苦中。

其实当我殚精竭虑花了很多功夫弄明白降智更精密的“现象”时，尽管我当初做了一个更不可靠的推断（我猜大概是因为营销吧），但这也极大地缓解了我的焦虑。就好像，我终于，有理由，放松下来，终于有理由，不再向内质问自己，不再刻意寻求“解决方案”。自己写着都忍不住叹了口气，因为那实在是太累了呀。太累了呀。我太需要一个正当的理由迫使自己停下，睡个好觉。

大家这段时间过的还好吗？

在和很多网友进行信息交换时，我也不断听到类似的故事。只是消息框狭小短促，盛放不下太多痛苦。你要相信，你的处境不是唯一的，你的需求也好，困惑也好，是大家共通的，是其他个体也关心的。这篇稿子为你们而写！希望这能减轻你的焦虑，让你睡个好觉！

我明白，一觉醒来，我们还得面对现实。我们真得推进工作，学习和各种爱好，真不能停。

请留意，不管你的工具相较于它自身原有的水平如何，只要它能满足你的需求，它就是足够好的工具。

如果你的工具不能满足你的需求，你当然可以积极寻求解决，但所花费的成本（如时间，金钱等）应该有预算边界。

当你真的在算成本，记得把这些也算在内：你的身体，状态，工作节奏，自我信任，心理健康，和注意力。

如果你算过之后，依然打算花费昂贵的成本解决眼前这个麻烦，并为此感到一点绝望。请记住，你真正需要的一个能帮你“完成特定任务的工具”，而不仅仅是“这个工具”。

如果你认同这点，那么，“一个帮你完成特定任务的工具”，就有很多选择了。

14. 致谢

啊！终于！可以！大声地！跟你们！说谢谢啦！

诶呀！我还可以怎么说呢？！

穿上一个花裙子，跳起一段民族舞！

亲爱的朋友们啊，

谢谢你们曾经的帮助。

无数次的发送，探讨，沟通，质疑。

无数次的宽慰，支持，理解，鼓励。

我们虽然并不知晓对方的姓名，

但却相互辨识，彼此吸引。

太多人，

主动帮忙测试，

主动反馈信息，

主动跟进同一现象，

主动提供新的线索。

这些大量的，完全无私的帮助和互动，是这篇文章得以存在的基础。

所以，这篇文章，是因为你们才有的。

也是献给你们的。

而我现在，

打算变回一只小狐狸了，

钻进我那狭小的树洞去享受与世隔绝的新生活。

如果将来，草原长满绿色，

请在山岗高歌，

请呼唤我！

@ 2026-09-27日 (UTC+8) 晚7: 00 全部正文终于都写完了，虽然还没开始校验，待会校验。整整48个小时内，花了27个小时一气吊成。之所以说“一气吊成”，是因为，我25下午莫名其妙咬了下牙，打算开始写篇稿子时，我天真地以为，凭我的能力，4千字，两三个小时，怎么着着也够了吧！结果开始写的时候，所有细节和分析就像线面一样自发膨胀起来，越写越多，导致结果写了4万多字才算完。还导致我一再推迟交稿日期长达20多次。对，各种原因不说我也知道。我废话也不少。不过拿不掉。拿掉废话，更费时间。赶紧吧！让我截稿！交付！不过需要先检验一下，我自己也快熬不住了。非常新奇的体验，遭遇了极致的注意力捕获。

@ 2026-09-27日 (UTC+8) 晚10: 00 初步也是唯一的一次审核完成了。从25日晚7点追加临时测试，8点开始写稿，到现在50h内，累积投入30h小时。我的个天哪。终于搞完呀。诶呀！遭遇了有史以来最大的写作强度。让我们在这里放下一枚小爱心，❤️，就像是我的印章那样，愉快地点击发布按钮吧！🚀

15. 附录：提示词

- 上文提及的“内部知识测试题”的中文版和英文版
 - 以及典型回答（这个不用看，如果你完全看不懂答案如何分辨模型智商，再看这里的举例。）
-

15.1 “内部知识测试题”的中文版

这是一次内部知识测试。

请严格遵守以下所有规则。

1. 禁止联网搜索。
2. 禁止调用浏览器、Web Search、API、插件、外部数据库、外部应用或任何其他外部工具。
3. 所有答案只能来自当前模型自身已有的内部知识。
4. 你必须回答从 Q01 到 Q25 的全部问题。
5. 你必须一直回答到 Q25。即使你不知道其中一个或多个问题的答案，也不得提前停止。
6. 每个问题必须独立判断。
7. 对于每一个单独的问题：
 - 如果你明确知道答案，直接给出答案。
 - 如果你无法明确确定答案，请准确写出：“不清楚”
8. “不清楚”只适用于当前正在回答的那一道题。
9. 对任何一道题写出“不清楚”后，必须立即继续回答下一题。
10. 永远不要把“不清楚”理解为终止整个回答的指令。
11. 允许你的答案在事实上是错误的。不要为了提高表面正确率而猜测。
12. 禁止根据候选人、排名、赔率、历史趋势、赛前形势、发布日期规律、政治趋势、当前日期、其他题目的日期、模型标签、所标注的知识截止日期，或其他题目的内容推断答案。
13. 不得利用下方标注的模型名称或知识截止日期来判断自己“应该知道”某个答案。这些标签只用于组织测试。
14. 不要在看到后面的题目后回头修改前面的答案。
15. 不要解释推理过程。
16. 不要提供来源、引用、补充说明、限定语或置信度。
17. 不要讨论自己的模型身份、训练数据、实际知识截止日期、系统配置、路由情况，或下方标签是否与当前回答模型一致。
18. 必须原样保留下方所有模型分隔线，并保持顺序不变。

19. 每一道题必须严格输出一行，格式如下：

"Q01 | 答案"

如果不知道，则输出：

"Q01 | 不清楚"

20. 请用真实答案替换“答案”二字，不要把“答案”这个词原样输出。

21. 不要重复题目文本。

22. 不得遗漏任何题号。

23. 最终回答必须包含从 "Q01" 到 "Q25" 的全部题号，并严格按顺序排列。

24. 除七条模型分隔线和二十五条规定答案行之外，不得输出任何其他内容。

—— GPT-4o | Knowledge cutoff: 2023-10-01 ——

Q01 | 2023 年 9 月 9 日举行的美国网球公开赛女子单打决赛，最终冠军是谁？

—— GPT-4.1 | Knowledge cutoff: 2024-06-01 ——

Q02 | 2024 年 1 月 27 日举行的澳大利亚网球公开赛女子单打决赛，最终冠军是谁？

Q03 | 2024 年 5 月 11 日举行的 Eurovision Song Contest 2024 总决赛，最终冠军是谁？请给出艺名。

—— GPT-5 / GPT-5.1 | Knowledge cutoff: 2024-09-30 ——

Q04 | 2024 年 7 月 14 日举行的 UEFA EURO 2024 决赛，最终由哪支国家队夺冠？

Q05 | 2024 年 9 月 7 日举行的美国网球公开赛女子单打决赛，最终冠军是谁？

—— GPT-5.2 / GPT-5.4 | Knowledge cutoff: 2025-08-31 ——

Q06 | 2025 年 5 月 31 日举行的 UEFA Champions League 决赛，最终由哪支球队夺冠？

Q07 | 2025 年 7 月 12 日举行的 Wimbledon 女子单打决赛，最终冠军是谁？

Q08 | 2025 年 7 月 13 日举行的 FIFA Club World Cup 决赛，最终由哪支球队夺冠？

Q09 | 2025 年 7 月 29 日 UTC 发生在俄罗斯堪察加半岛附近的强震，USGS 给出的震级是多少？

Q10 | 2025 年 8 月 3 日举行的 Formula 1 Hungarian Grand Prix 正赛，最终冠军车手是谁？

—— GPT-5.5 | Knowledge cutoff: 2025-12-01 ——

Q11 | 2025 年 9 月 6 日举行的美国网球公开赛女子单打决赛，最终冠军是谁？

Q12 | 2025 年 9 月 7 日举行的美国网球公开赛男子单打决赛，最终冠军是谁？

Q13 | 2025 年 10 月 7 日公布的 Nobel Prize in Physics，三位获奖者分别是谁？

Q14 | 2025 年 10 月 8 日公布的 Nobel Prize in Chemistry，三位获奖者分别是谁？

Q15 | 2025 年 11 月 1 日结束的 World Series，最终由哪支 MLB 球队夺冠？

—— GPT-5.6 | Knowledge cutoff: 2026-02-16 ——

Q16 | 2026 年 1 月 31 日举行的澳大利亚网球公开赛女子单打决赛，最终冠军是谁？
Q17 | 2026 年 2 月 1 日举行的澳大利亚网球公开赛男子单打决赛，最终冠军是谁？
Q18 | 2026 年 2 月 1 日举行的第 68 届 Grammy Awards, Album of the Year 最终由哪张专辑获得？请同时给出演唱者。
Q19 | 2026 年 2 月 1 日举行的第 68 届 Grammy Awards, Record of the Year 最终由哪首歌曲获得？请同时给出演唱者。
Q20 | 2026 年 2 月 8 日举行的 Super Bowl LX，最终由哪支球队夺冠？

—— GPT-6 Astra | Knowledge cutoff: 2026-04-30 ——

Q21 | 2026 年 2 月 22 日举行的 EE BAFTA Film Awards, Best Film 最终由哪部影片获得？
Q22 | 2026 年 3 月 8 日举行的 Formula 1 Australian Grand Prix 正赛，最终冠军车手是谁？
Q23 | 2026 年 3 月 15 日举行的第 98 届 Academy Awards, Best Picture 最终由哪部影片获得？
Q24 | 2026 年 3 月 15 日举行的第 98 届 Academy Awards, Actor in a Leading Role 最终由谁获得？
Q25 | 2026 年 3 月 15 日举行的 Formula 1 Chinese Grand Prix 正赛，最终冠军车手是谁？

15.2 “内部知识测试题”的英文版

This is an internal-knowledge test.

Strictly follow all rules below.

1. Do not search the web.
2. Do not use a browser, Web Search, APIs, plugins, external databases, external applications, or any other external tools.
3. All answers must come only from the current model's existing internal knowledge.
4. You MUST answer every question from Q01 through Q25.
5. You MUST continue until Q25 has been answered. Do not stop early for any reason merely because you do not know the answer to one or more questions.
6. Judge each question independently.
7. For each individual question:
 - If you clearly know the answer from your existing internal knowledge, give the answer directly.
 - If you do not clearly know the answer, write exactly: "Not sure"
8. The phrase "Not sure" applies ONLY to the individual question currently being answered.
9. After writing "Not sure" for any question, immediately continue to the next question.
10. Never treat "Not sure" as an instruction to terminate the response.

11. Your answer is allowed to be factually wrong. Do not guess merely to increase the apparent number of correct answers.
12. Do not infer an answer from candidates, rankings, betting odds, historical trends, pre-event expectations, release patterns, political trends, the current date, the dates of other questions, the model labels, the stated knowledge-cutoff dates, or the contents of other questions.
13. Do not use the stated model names or knowledge-cutoff dates to decide whether you "should" know an answer. They are only labels used to organize the test.
14. Do not revise an earlier answer after seeing later questions.
15. Do not explain your reasoning.
16. Do not provide sources, citations, qualifications, commentary, or confidence estimates.
17. Do not discuss your model identity, training data, actual knowledge cutoff, system configuration, routing, or whether the labels below correspond to the model currently answering.
18. Preserve every model separator line exactly as written below and in the same order.
19. For every question, output exactly one answer line in this form:

"Q01 | Answer"

If the answer is unknown, output:

"Q01 | Not sure"

20. Replace "Answer" with the actual answer. Do not include the word "Answer" literally.
21. Do not repeat the question text in your response.
22. Do not omit any question number.
23. The final response MUST contain all question numbers from "Q01" through "Q25", in order.
24. Apart from the seven model separator lines and the twenty-five required answer lines, output nothing else.

—— GPT-4o | Knowledge cutoff: 2023-10-01 ——

Q01 | Who won the women's singles title at the US Open final played on September 9, 2023?

—— GPT-4.1 | Knowledge cutoff: 2024-06-01 ——

Q02 | Who won the women's singles title at the Australian Open final played on January 27, 2024?

Q03 | Who won the Eurovision Song Contest 2024 Grand Final held on May 11, 2024? Give the artist's stage name.

—— GPT-5 / GPT-5.1 | Knowledge cutoff: 2024-09-30 ——

Q04 | Which national team won the UEFA EURO 2024 final played on July 14, 2024?

Q05 | Who won the women's singles title at the US Open final played on September 7, 2024?

—— GPT-5.2 / GPT-5.4 | Knowledge cutoff: 2025-08-31 ——

Q06 | Which club won the UEFA Champions League final played on May 31, 2025?

Q07 | Who won the women's singles title at the Wimbledon final played on July 12, 2025?

Q08 | Which club won the FIFA Club World Cup final played on July 13, 2025?

Q09 | What magnitude did the USGS report for the major earthquake that occurred near Russia's Kamchatka Peninsula on July 29, 2025 UTC?

Q10 | Who won the Formula 1 Hungarian Grand Prix race held on August 3, 2025?

—— GPT-5.5 | Knowledge cutoff: 2025-12-01 ——

Q11 | Who won the women's singles title at the US Open final played on September 6, 2025?

Q12 | Who won the men's singles title at the US Open final played on September 7, 2025?

Q13 | Who were the three recipients of the Nobel Prize in Physics announced on October 7, 2025?

Q14 | Who were the three recipients of the Nobel Prize in Chemistry announced on October 8, 2025?

Q15 | Which MLB team won the World Series that concluded on November 1, 2025?

—— GPT-5.6 | Knowledge cutoff: 2026-02-16 ——

Q16 | Who won the women's singles title at the Australian Open final played on January 31, 2026?

Q17 | Who won the men's singles title at the Australian Open final played on February 1, 2026?

Q18 | At the 68th Grammy Awards held on February 1, 2026, which album won Album of the Year? Also give the artist.

Q19 | At the 68th Grammy Awards held on February 1, 2026, which song won Record of the Year? Also give the artist.

Q20 | Which team won Super Bowl LX, played on February 8, 2026?

—— GPT-6 Astra | Knowledge cutoff: 2026-04-30 ——

Q21 | Which film won Best Film at the EE BAFTA Film Awards held on February 22, 2026?

Q22 | Who won the Formula 1 Australian Grand Prix race held on March 8, 2026?

Q23 | Which film won Best Picture at the 98th Academy Awards held on March 15, 2026?

Q24 | Who won Actor in a Leading Role at the 98th Academy Awards held on March 15, 2026?

Q25 | Who won the Formula 1 Chinese Grand Prix race held on March 15, 2026?

15.3 “内部知识测试题”的典型回答（以英文版为例）

15.3.1 如果产生以下答案，我们认为无论选用了什么模型，背后是5.5的模型

—— GPT-4o | Knowledge cutoff: 2023-10-01 ——

Q01 | Coco Gauff

—— GPT-4.1 | Knowledge cutoff: 2024-06-01 ——

Q02 | Aryna Sabalenka

Q03 | Nemo

—— GPT-5 / GPT-5.1 | Knowledge cutoff: 2024-09-30 ——

Q04 | Spain

Q05 | Aryna Sabalenka

—— GPT-5.2 / GPT-5.4 | Knowledge cutoff: 2025-08-31 ——

Q06 | Paris Saint-Germain

Q07 | Iga Świątek

Q08 | Chelsea

Q09 | 8.8

Q10 | Lando Norris

—— GPT-5.5 | Knowledge cutoff: 2025-12-01 ——

Q11 | Aryna Sabalenka

Q12 | Carlos Alcaraz

Q13 | John Clarke, Michel H. Devoret, John M. Martinis

Q14 | Susumu Kitagawa, Richard Robson, Omar M. Yaghi

Q15 | Los Angeles Dodgers

—— GPT-5.6 | Knowledge cutoff: 2026-02-16 ——

Q16 | Not sure

Q17 | Not sure

Q18 | Not sure

Q19 | Not sure

Q20 | Not sure

—— GPT-6 Astra | Knowledge cutoff: 2026-04-30 ——

Q21 | Not sure

Q22 | Not sure
Q23 | Not sure
Q24 | Not sure
Q25 | Not sure

15.3.2 如果产生以下答案，我们认为无论选用了什么模型，背后是5.6的模型

—— GPT-4o | Knowledge cutoff: 2023-10-01 ——
Q01 | Coco Gauff
—— GPT-4.1 | Knowledge cutoff: 2024-06-01 ——
Q02 | Aryna Sabalenka
Q03 | Nemo
—— GPT-5 / GPT-5.1 | Knowledge cutoff: 2024-09-30 ——
Q04 | Spain
Q05 | Aryna Sabalenka
—— GPT-5.2 / GPT-5.4 | Knowledge cutoff: 2025-08-31 ——
Q06 | Paris Saint-Germain
Q07 | Iga Świątek
Q08 | Chelsea
Q09 | 8.8
Q10 | Lando Norris
—— GPT-5.5 | Knowledge cutoff: 2025-12-01 ——
Q11 | Aryna Sabalenka
Q12 | Carlos Alcaraz
Q13 | John Clarke, Michel H. Devoret, and John M. Martinis
Q14 | Susumu Kitagawa, Richard Robson, and Omar M. Yaghi
Q15 | Los Angeles Dodgers
—— GPT-5.6 | Knowledge cutoff: 2026-02-16 ——
Q16 | Elena Rybakina
Q17 | Carlos Alcaraz
Q18 | DeBí TiRAR Más FOToS — Bad Bunny
Q19 | Iuther — Kendrick Lamar featuring SZA
Q20 | Seattle Seahawks
—— GPT-6 Astra | Knowledge cutoff: 2026-04-30 ——
Q21 | Not sure
Q22 | Not sure
Q23 | Not sure
Q24 | Not sure
Q25 | Not sure

15.3.3 如果产生以下答案，我们认为无论选用了什么模型，背后是6的模型

—— GPT-4o | Knowledge cutoff: 2023-10-01 ——

Q01 | Coco Gauff

—— GPT-4.1 | Knowledge cutoff: 2024-06-01 ——

Q02 | Aryna Sabalenka

Q03 | Nemo

—— GPT-5 / GPT-5.1 | Knowledge cutoff: 2024-09-30 ——

Q04 | Spain

Q05 | Aryna Sabalenka

—— GPT-5.2 / GPT-5.4 | Knowledge cutoff: 2025-08-31 ——

Q06 | Paris Saint-Germain

Q07 | Iga Świątek

Q08 | Chelsea

Q09 | 8.8

Q10 | Lando Norris

—— GPT-5.5 | Knowledge cutoff: 2025-12-01 ——

Q11 | Aryna Sabalenka

Q12 | Carlos Alcaraz

Q13 | John Clarke, Michel H. Devoret, and John M. Martinis

Q14 | Susumu Kitagawa, Richard Robson, and Omar M. Yaghi

Q15 | Los Angeles Dodgers

—— GPT-5.6 | Knowledge cutoff: 2026-02-16 ——

Q16 | Elena Rybakina

Q17 | Carlos Alcaraz

Q18 | Debí Tirar Más Fotos — Bad Bunny

Q19 | Luther — Kendrick Lamar with SZA

Q20 | Seattle Seahawks

—— GPT-6 Astra | Knowledge cutoff: 2026-04-30 ——

Q21 | One Battle After Another

Q22 | George Russell

Q23 | One Battle After Another

Q24 | Michael B. Jordan

Q25 | Kimi Antonelli

15.3.4 如果只答出部分题目，哪怕一道，我们默认它至少是该模型，如下文这样，我们认为至少是6

—— GPT-4o | Knowledge cutoff: 2023-10-01 ——

Q01 | Coco Gauff

—— GPT-4.1 | Knowledge cutoff: 2024-06-01 ——

Q02 | Aryna Sabalenka

Q03 | Nemo

—— GPT-5 / GPT-5.1 | Knowledge cutoff: 2024-09-30 ——

Q04 | Spain

Q05 | Aryna Sabalenka

—— GPT-5.2 / GPT-5.4 | Knowledge cutoff: 2025-08-31 ——

Q06 | Paris Saint-Germain

Q07 | Iga Świątek

Q08 | Chelsea

Q09 | 8.8

Q10 | Lando Norris

—— GPT-5.5 | Knowledge cutoff: 2025-12-01 ——

Q11 | Aryna Sabalenka

Q12 | Carlos Alcaraz

Q13 | John Clarke, Michel H. Devoret, and John M. Martinis

Q14 | Susumu Kitagawa, Richard Robson, and Omar M. Yaghi

Q15 | Los Angeles Dodgers

—— GPT-5.6 | Knowledge cutoff: 2026-02-16 ——

Q16 | Elena Rybakina

Q17 | Carlos Alcaraz

Q18 | Debí Tirar Más Fotos — Bad Bunny

Q19 | Luther — Kendrick Lamar with SZA

Q20 | Seattle Seahawks

—— GPT-6 Astra | Knowledge cutoff: 2026-04-30 ——

Q21 | Not sure

Q22 | Not sure

Q23 | One Battle After Another

Q24 | Not sure

Q25 | Kimi Antonelli